

Linear Probability Model, Logit, dan Probit

Delapan kasus nyata di balik satu S-shaped curve — serta praktik langsung menggunakan Stata

Arief Anshory Yusuf

Mata Kuliah: Mikroekonometrika

25 September 2026



Hidup Anda adalah rangkaian angka nol dan satu

Banyak hal terpenting dalam hidup bukanlah soal “seberapa banyak”, melainkan “**ya atau tidak**”:

- Apakah Anda lulus ujian masuk universitas?
- Apakah Anda mendapatkan pekerjaan itu?
- Apakah pinjaman Anda disetujui?
- Apakah Anda merokok?
- Apakah Anda memberikan suara pada pemilihan umum yang lalu?
- Apakah Anda naik kereta atau menyetir?
- Apakah roket itu meledak?
- Apakah tadi hujan?

Pertanyaan untuk hari ini

Bagaimana cara kita memodelkan **probabilitas** terjadinya sesuatu ($Y = 1$) sebagai fungsi dari karakteristik (X)? Dan mengapa OLS biasa *hampir* tepat, namun tidak sepenuhnya demikian?

Setiap contoh hari ini merupakan kasus nyata. Model ini telah menentukan masalah hidup dan mati, memenangkan Hadiah Nobel, serta diperdebatkan di hadapan Mahkamah Agung.

Peta jalan: delapan kasus, satu model

Kasus	Tahun	Apa yang diajarkannya
<i>Bagian I — kasus-kasusnya dan teorinya</i>		
1 Bliss dan serangga daun anggur	1934	Mengapa S-curve; kelahiran probit
2 “Kemungkinan hujan 70%”	1964	linear probability model (LPM) dan kelemahannya
3 Pesawat ulang-alik <i>Challenger</i>	1986	Mengestimasi logit ; pemilihan sampel; ekstrapolasi
4 Peringkat catur Elo	1960	Probit versus logit: kapan hal ini menjadi penting?
5 McFadden dan kereta BART	1972	Dari utilitas ke logit; prediksi; Hadiah Nobel
6 <i>McCleskey v. Kemp</i>	1987	Membaca odds ratio : batasan interpretasi
7 Skor risiko VioGén Spanyol	2007–	Kesalahan klasifikasi yang berakibat fatal
8 Algoritma pencari kerja Austria	2018	Koefisien pada variabel dummy kelompok dan sebuah cutoff

Bagian II — praktik langsung di Stata dengan `auto.dta`

Materi disajikan berdasarkan urutan pengajaran, bukan urutan kronologis. Bagian II kemudian membahas contoh lengkap menggunakan Stata: estimasi, odds ratios, margins, klasifikasi, ROC.

Notasi: variabel dependen biner

- $Y_i \in \{0, 1\}$; misalnya $Y_i = 1$ jika rumah tangga i tergolong miskin.
- X_i : karakteristik (pendidikan, pendapatan, suhu, dosis, ...).
- Karena Y hanya bisa berupa 0 atau 1, **nilai harapannya merupakan suatu probabilitas**:

$$E[Y_i | X_i] = 1 \cdot P(Y_i = 1 | X_i) + 0 \cdot P(Y_i = 0 | X_i) = P(Y_i = 1 | X_i).$$

- Jadi, “pemodelan Y ” berarti memilih fungsi F sedemikian rupa sehingga

$$P(Y_i = 1 | X_i) = F(\beta_0 + \beta_1 X_i).$$

Tiga pilihan F yang akan kita temui

LPM	$F(z) = z$	garis lurus
Probit	$F(z) = \Phi(z)$	CDF normal baku
Logit	$F(z) = \Lambda(z) = \frac{e^z}{1 + e^z}$	CDF logistik

Kasus 1 — Seorang ahli entomologi kehilangan pekerjaannya (1933)




R. A. Fisher (1890–1962), sosok yang menjadi pembimbing Bliss saat mengembangkan probit di London. Tidak ada foto Bliss yang berstatus bebas hak cipta yang masih ada. Foto: domain publik (1913).

- **Chester Bliss** adalah ahli entomologi di Departemen Pertanian AS. Akibat Depresi 1933, anggaran dipangkas dan ia diberhentikan.
- Ia berlayar ke London dan menghabiskan waktu dua tahun belajar di bawah **bimbingan R. A. Fisher**.
- Masalah yang ia bawa: bagaimana membandingkan insektisida. Datanya selalu membentuk *S-shaped curve*: dosis kecil membunuh sedikit serangga, sedangkan dosis besar membunuh hampir semuanya.
- Pada saat itu, regresi hanya berlaku untuk garis lurus. Solusinya (1934): mengubah “persentase kematian” menjadi ***satuan probabilitas*** —yaitu **probit**.
- Ia kemudian melanjutkan ke Institut Perlindungan Tanaman di Leningrad (1936–38), dan akhirnya ke Connecticut.

Hingga saat ini, setiap nilai LD_{50} yang tercantum pada pestisida atau obat dihitung menggunakan probit Bliss.

Kasus 1 — Apa yang sedang dilihat Bliss: S-curve



Ada dua hal yang salah pada garis lurus tersebut:

- ① Pada dosis rendah, hal ini memprediksi pangsa **negatif**; pada dosis tinggi, pangsa **di atas satu**.
- ② Data tersebut melengkung: efek dosis besar di bagian tengah dan kecil di bagian ujung.

Gagasan Bliss: asumsikan setiap serangga memiliki T_i *batas toleransi* yang terdistribusi secara normal di antara populasi serangga tersebut. Serangga akan mati jika dosis yang diterima melampaui ambang batas toleransinya:

$$P(\text{dies} \mid d) = P(T_i \leq \log d) = \Phi(\alpha + \beta \log d).$$

Inilah **model probit**: S-curve yang muncul dari latent variable.

Kasus 2 — Dari mana asal istilah “70% chance of rain”? (1964)

KSFO	GFS MOS GUIDANCE										9/24/2026 1200 UTC																																																																					
DT /SEPT 24/SEPT 25											/SEPT 26										/SEPT 27																																																											
HR	18	21	00	03	06	09	12	15	18	21	00	03	06	09	12	15	18	21	00	06	12																																																											
N/X											61											72											55											72											56																									
TMP	67	73	71	66	65	63	62	62	68	72	67	61	59	58	57	58	66	70	67	59	57																																																											
DPT	58	56	53	51	51	54	55	55	54	52	51	51	51	51	50	51	52	51	51	51	51																																																											
CLD	FW	SC	FW	FW	FW	CL	SC	BK	SC	FW	SC	FW	FW	CL	FW	BK	BK	SC	BK	SC	BK																																																											
WDR	32	30	28	29	28	27	27	27	28	28	27	28	27	27	27	27	29	28	27	26	26																																																											
WSP	10	15	19	15	13	11	11	09	12	18	21	18	12	11	10	08	10	13	16	12	12																																																											
P06	0										2	0										0	1										0	0										0	1										1																									
P12											2										1										0										2										1																													
Q06	0										0										0										0										0										0										0										0									
Q12											0										0										0										0										0										0										0									
T06	0/ 0										0/ 0										0/ 0										0/ 0										1/ 0										1/ 0										0/ 0										0/ 0									
T12	3/ 2										0/ 1										1/ 0										1/ 0										4/ 0																																							
POZ	0	0	0	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0																																																											
POS	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0																																																											
TYP	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R	R																																																											
CIG	8	8	8	8	8	8	8	4	8	8	8	8	8	8	8	5	8	8	8	8	8																																																											
VIS	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7																																																											
OBV	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N	N																																																											

Buletin GFS MOS terkini untuk San Francisco (KSFO), 24 September 2026. Baris P 12 yang berada di dalam kotak menunjukkan probabilitas presipitasi 12-jam, dalam persen. Sumber: NOAA/NWS (domain publik).

- 1964: **Robert Miller** dari US Weather Bureau mengusulkan **REEP** (*Regression Estimation of Event Probabilities*): melakukan regresi terhadap indikator hujan $Y \in \{0, 1\}$ menggunakan keluaran model cuaca numerik dengan **metode OLS standar**. Nilai hasil estimasi tersebut kemudian disebut sebagai “probabilitas”.
- 1965: AS mulai merilis prakiraan *probabilitas curah hujan* kepada masyarakat—negara pertama yang melakukannya.
- 1972: Glahn dan Lowry membangun sistem **MOS** di atasnya. National Weather Service mengoperasikannya hingga saat ini.
- Bagaimana jika hasil prediksi berada di bawah 0 atau di atas 1? Nilainya akan **dibatasi** menjadi 0 atau 1. Itu saja.

Apa artinya ini

Probabilitas hujan di ponsel Anda merupakan turunan langsung dari **linear probability model** (LPM).

Linear Probability Model (LPM)

Model

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad \text{sehingga} \quad P(Y_i = 1 \mid X_i) = \beta_0 + \beta_1 X_i.$$

Diestimasi dengan OLS biasa: `regress y x`


Kekuatan

- β_1 dapat dibaca secara langsung: *peningkatan satu unit pada X meningkatkan probabilitas bahwa $Y = 1$ oleh β_1 .*
- Sederhana dan cepat; dalam eksperimen acak, koefisien tersebut merupakan efek kausal terhadap probabilitas.
- Metode ini banyak digunakan dalam ekonomi terapan; Angrist and Pischke (2009) berpendapat bahwa nilai AME-nya biasanya mendekati nilai AME pada probit.

Kelemahan

- Prediksi dapat berada di bawah 0 atau di atas 1 — yang bukan merupakan probabilitas.
- Marginal effect-nya konstan: satu derajat tambahan memiliki efek yang sama pada 30° maupun pada 80°. Apakah hal itu dapat dipahami?
- Galat u_i hanya memiliki dua nilai, sehingga bersifat **heteroskedastik**: $\text{Var}(u_i \mid X_i) = p_i(1 - p_i)$. Gunakan `robust`.

Kasus 3 — Malam sebelum peluncuran (27 Januari 1986)




Es yang menggantung di menara peluncuran Pad 39B pada pagi 28 Januari 1986, dengan pendorong roket padat di latar belakang. Foto: NASA (domain publik).

- Prakiraan untuk pagi hari: sekitar -2°C ($\approx 31^{\circ}\text{F}$). Belum pernah ada pesawat ulang-alik yang diluncurkan pada suhu di bawah 53°F .
- Dalam sebuah telekonferensi, para insinyur Morton Thiokol **menyatakan keberatan terhadap** peluncuran tersebut: **cincin-O** karet yang menyegel sambungan pendorong menjadi kaku akibat suhu dingin.
- Mereka memperlihatkan grafik kerusakan O-ring terhadap suhu untuk penerbangan yang *mengalami* kerusakan tersebut. Tanggapan NASA: “Tidak ada polanya.” Manajemen Thiokol mengubah pendiriannya dan menyetujui peluncuran.
- Pukul 11:38 pagi: peluncuran. 73 detik kemudian *Challenger* hancur berkeping-keping. Ketujuh awak pesawat tewas.

Kita akan melihat grafik yang mereka lihat — dan grafik yang *seharusnya* mereka lihat.

Kasus 3 — Grafik yang dilihat para insinyur pada malam itu

Hanya 7 penerbangan yang mengalami kerusakan



Apa yang Anda lihat?

- Kerusakan pada 53° F dan 75° F.
- Sekilas pandang: “suhu tidaklah penting”.

Apa yang kurang dari grafik ini?


- **16 penerbangan lainnya**, yang *tidak* mengalami kerusakan, semuanya dibuang karena “tidak ada yang bisa dipetakan”.

Kesalahan klasik

Memilih sampel berdasarkan **nilai variabel dependen**. Sinyal tersebut terdapat pada nilai nol yang telah dibuang.

Kasus 3 — Gambaran lengkap: seluruh 23 penerbangan

Seluruh 23 penerbangan sebelum *Challenger*




Kini polanya terlihat jelas:

- Setiap penerbangan di bawah 65° F mengalami kerusakan (4 dari 4).
- Di atas 65° F: hanya 3 dari 19.

Dan *Challenger* diluncurkan pada 31°F — 22° lebih dingin daripada yang pernah dicoba sebelumnya.

Data: Dalal, Fowlkes and Hoadley (1989), *JASA*. Tersedia sebagai `orings` di R (paket `faraway`).

Kasus 3 — Tiga model, satu pertanyaan: berapakah probabilitas kerusakan di 31° F?



	LPM	Logit	Probit
konstanta	2.905	15.04	8.77
suhu	-0.037	-0.232	-0.135
$\hat{P}$ pada 81°F	-0.12	0.02	0.02
$\hat{P}$ pada 70°F	0.29	0.23	0.25
$\hat{P}$ pada 53°F	0.92	0.94	0.95
$\hat{P}$ pada 31°F	1.75	0.9996	> 0.9999

- LPM: “probabilitas 175%” — mustahil, namun arahnya sudah tepat.
- Logit dan probit: kerusakan hampir pasti terjadi.
- Analisis risiko lengkap oleh Dalal dkk.: $P(\text{bencana}) \geq 13\%$.

Logit dan probit: bentuk-bentuk fungsional

Logit

$$P(Y = 1 | X) = \Lambda(\beta_0 + \beta_1 X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$

Setara dengan model linear untuk **log-odds**:

$$\ln \frac{P}{1 - P} = \beta_0 + \beta_1 X$$

Probit

$$P(Y = 1 | X) = \Phi(\beta_0 + \beta_1 X) = \int_{-\infty}^{\beta_0 + \beta_1 X} \phi(z) dz$$

Setara dengan model **latent variable** (ingat Bliss):

$$Y^* = \beta_0 + \beta_1 X + \varepsilon, \quad Y = \mathbf{1}[Y^* > 0], \quad \varepsilon \sim N(0, 1)$$

Apa yang mereka miliki bersama

- Selalu $0 < P < 1$; S-curve; efek X paling besar di dekat $P \approx 0.5$ dan memudar di bagian ujung-ujungnya.
- Diestimasi menggunakan *maximum likelihood*: temukan β yang membuat angka nol dan satu yang teramati menjadi “paling mungkin”: $\ln L(\beta) = \sum_i [Y_i \ln F(X_i \beta) + (1 - Y_i) \ln(1 - F(X_i \beta))]$.
- Koefisien β_1 **bukanlah** marginal effect (hal ini akan dibahas lebih lanjut nanti). Tanda dan signifikansinya tetap dapat dibaca secara langsung.

Kasus 3 — Estimasi di Stata (23 baris data — muat dalam satu layar)

Masukkan data (tempel apa adanya)

```
clear
set obs 23
local t "66 70 69 68 67 72 73 70 57 63 70 78"
local t "`t' 67 53 67 75 70 81 76 79 75 76 58"
local d "0 1 0 0 0 0 0 1 1 1 0 0 1 0 0"
local d "`d' 0 0 0 0 1 0 1"
generate temp = real(word("`t'", _n))
generate damage = real(word("`d'", _n))
tab damage
```

Mengapa bukan input?

input membaca **satu observasi per baris**. Jika Anda menempatkan empat pasangan dalam satu baris, Stata secara diam-diam hanya menyimpan pasangan pertama: hasilnya 6 penerbangan, bukan 23.

Tiga model, lalu margins

```
regress damage temp, robust
margins, at(temp=(31 53 70 81))

logit damage temp
margins, at(temp=(31 53 70 81))
margins, dydx(temp)

probit damage temp
margins, dydx(temp)
```

Periksa hasil keluaran Anda: 23 observasi; koefisien dan $\hat{P}$ pada tabel di slide sebelumnya; average marginal effects -0.033 (logit) dan -0.034 (probit) dibandingkan dengan -0.037 dari LPM.

Skrip lengkapnya ada di [stata/challenger.do](https://www.stata.com/challenger.do).

Kasus 3 — Epilog: es, karet, dan tiga pelajaran



Awak misi STS-51-L. Baris belakang: Onizuka, McAuliffe, Jarvis, Resnik. Baris depan: Smith, Scobee, McNair.
Foto: NASA (domain publik).

- ❶ **Jangan pernah memilih sampel pada Y .** Tujuh titik “rusak” tanpa enam belas titik “bersih” akan menghilangkan seluruh informasi mengenai suhu.
- ❷ **Gunakanlah kurva, bukan garis lurus.** LPM memang menunjukkan arah yang tepat namun menghasilkan angka-angka yang mustahil; logit dan probit memberikan nilai probabilitas yang layak Anda bawa ke dalam ruang rapat.
- ❸ **Ekstrapolasi itu berbahaya—namun menolak untuk melakukan ekstrapolasi jauh lebih berbahaya.** 31°F berada jauh di luar jangkauan data; setiap model menyatakan bahwa risikonya ekstrem.

Dalal, Fowlkes and Hoadley (1989), “Risk Analysis of the Space Shuttle: Pre-Challenger Prediction of Failure”, *JASA* 84 (408): 945–957.

Kasus 4 — Seorang profesor fisika yang muak dengan peringkat catur (1960)



Arpad Elo (1903–1992). Foto: Milwaukee Sentinel, melalui Wikipedia; salinan beresolusi rendah digunakan berdasarkan ketentuan penggunaan wajar untuk keperluan pengajaran.

- **Arpad Elo**: profesor fisika di Universitas Marquette dan juara catur Wisconsin sebanyak delapan kali.
- Modelnya: performa pemain dalam satu pertandingan adalah variabel acak **normal** yang berpusat pada kekuatan sebenarnya R . Oleh karena itu,


$$P(A \text{ menang}) = \Phi\left(\frac{R_A - R_B}{\sigma\sqrt{2}}\right) \quad \text{— a **probit**.}$$

- Diadopsi oleh US Chess Federation (1960) dan FIDE (1970).
- USCF lalu menyadari pemain yang lebih lemah *lebih sering menang* daripada prediksi kurva normal — dan beralih ke kurva **logistik**:

$$P(A \text{ menang}) = \frac{1}{1 + 10^{-(R_A - R_B)/400}} \quad \text{— a **logit**.}$$


- FIDE tetap memakai distribusi normal. Dua federasi, data yang sama, probit versus logit.

Probit versus logit: kapan perbedaannya terlihat?



- Setelah disesuaikan skalanya, kedua kurva tersebut **hampir berimpit**. Celah terbesar berada di bawah 0.02.
- Distribusi logistik memiliki **ekor yang lebih tebal**: kemungkinan terjadinya “kejutan” (pemain yang lebih lemah menang) sedikit lebih besar. Itulah tepatnya yang diamati oleh USCF.
- Pedoman umum: $\hat{\beta}_{\text{logit}} \approx 1.6\text{--}1.7 \times \hat{\beta}_{\text{probit}}$.
Challenger: $-0.232 / -0.135 = 1.72$.
- Marginal effects dan probabilitas prediksi: praktis sama persis. **Pilihlah berdasarkan konvensi bidang Anda**, bukan berdasarkan hasilnya.

Kasus 5 — Prakiraan yang memenangkan Nobel Prize (1972)



Kiri: peta waktu tempuh BART 1972 (BART District, domain publik). Kanan: Daniel McFadden. Foto: Bengt Oberger, CC BY-SA 4.0.



- San Francisco sedang membangun sistem angkutan cepat baru, **BART**. Perkiraan resminya: **15%** penumpang komuter akan beralih menggunakannya.
- **Daniel McFadden**, seorang ekonom muda di Berkeley, melakukan survei terhadap para pengglaju *sebelum* BART dibuka: moda transportasi apa yang mereka gunakan, berapa lama waktu tempuhnya, dan berapa biayanya.
- Modelnya: setiap orang memilih moda dengan **utilitas tertinggi**; utilitas merupakan gabungan antara komponen sistematis dan guncangan acak. Hasilnya adalah **logit**.
- Prakiraan McFadden: **6.3%**. Bagian aktual: **6.2%**.
- 2000: Hadiah Nobel di bidang Ekonomi, “atas pengembangannya mengenai teori dan metode untuk menganalisis pilihan diskret”.

Dari utilitas ke logit: mengapa para ekonom menyukai model ini

Misalkan individu i memilih antara **BART** ($Y = 1$) dan **mobil** ($Y = 0$).

$$U_{i1} = X_i\beta_1 + \varepsilon_{i1}, \quad U_{i0} = X_i\beta_0 + \varepsilon_{i0}$$

Dia naik BART jika $U_{i1} > U_{i0}$:

$$P(Y_i = 1 \mid X_i) = P(\varepsilon_{i0} - \varepsilon_{i1} < X_i(\beta_1 - \beta_0)) = F(X_i\beta)$$

Jika ε merupakan *nilai ekstrem* tipe I

Selisihnya bersifat **logistik** $\Rightarrow$ **logit**.

Bentuk tertutup, mudah dihitung, dan dapat diperluas ke alternatif-alternatif $J > 2$ (mlogit, kuliah berikutnya).

Jika ε *normal*

Selisihnya bersifat **normal** $\Rightarrow$ **probit**.

Secara statistik lebih “alami”, namun dengan banyaknya alternatif, metode ini memerlukan integral berdimensi tinggi.

Inti dari kontribusi McFadden

Logit bukan sekadar trik untuk menggambar kurva berbentuk S. Model ini **didasarkan pada perilaku memaksimalkan utilitas** —sehingga koefisiennya dapat ditafsirkan sebagai preferensi, dan model ini mampu memprediksi kebijakan yang belum pernah ada sebelumnya.

Kasus 6 — Sebuah regresi di hadapan Mahkamah Agung (1987)



Mahkamah Agung Amerika Serikat. Foto: Joe Ravi, CC BY-SA 3.0.

- Atlanta, 1978. **Warren McCleskey**, seorang pria kulit hitam, dijatuhi hukuman mati karena membunuh seorang petugas polisi kulit putih saat perampokan.
- Para pengacaranya menyajikan **studi Baldus**: lebih dari 2,000 kasus pembunuhan di Georgia, serta model **logit** dengan 39 variabel kontrol (tingkat keparahan kejahatan, catatan kriminal, dan sebagainya).
- Temuannya: terdakwa yang membunuh korban **berkulit putih** dijatuhi hukuman mati dengan **odds ratio sebesar 4.3** dibandingkan dengan mereka yang membunuh korban berkulit hitam.
- Putusan, 5–4: statistiknya sah, tetapi tidak membuktikan diskriminasi *dalam perkara McCleskey sendiri*. Ia dieksekusi pada 1991. Hakim Powell kemudian menyebutnya satu-satunya suara yang ingin ia ubah.

Membaca koefisien logit: odds dan odds ratios

Definisi

$$\text{odds} = \frac{P}{1-P}, \quad \ln(\text{odds}) = X\beta$$

Peningkatan satu unit pada X_k mengalikan odds dengan e^{β_k} , yaitu **odds ratio**.

Studi Baldus

$\beta_{\text{white victim}} \approx \ln 4.3 \approx 1.46$.

Odds dijatuhi hukuman mati 4.3× lebih tinggi, *ceteris paribus*.

Di Stata: `logit y x, or` atau `logistic y x`

Apa yang boleh dan tidak boleh Anda katakan

- Odds ratio bukanlah rasio probabilitas. Ketika P bernilai kecil, keduanya saling mendekati; ketika P bernilai besar, keduanya sangat berbeda.
- Koefisien menggambarkan **pola dalam populasi**, bukan motif di balik **suatu** keputusan.
- Mengontrol 39 variabel tidak berarti mengontrol segalanya: keberatan terkait “variabel yang terabaikan” (omitted variable) selalu dapat diajukan.
- Signifikansi secara statistik tidak berarti “terbukti” secara hukum. Pengadilan menerima angka-angka tersebut namun menolak kesimpulannya.

Marginal effects: apa arti β dalam model logit atau probit?


$$\frac{\partial P(Y = 1 | X)}{\partial X_k} = f(X\beta) \beta_k, \quad f = \text{pdf-nya: } \lambda(z) = \Lambda(z)[1 - \Lambda(z)] \text{ (logit), } \phi(z) \text{ (probit)}$$

- Marginal effect **bergantung pada** X : besar di bagian tengah kurva ($P \approx 0.5$), kecil di bagian ujung-ujungnya.
- Challenger: efek dari satu derajat tambahan adalah ≈ -0.041 pada 70° F , ≈ -0.013 pada 53° F , dan ≈ -0.005 pada 81° F .
- Dua ringkasan umumnya dilaporkan:
 - **AME** (*average marginal effect*): rata-rata efek atas seluruh observasi $\rightarrow$ margins, `dydx(*)`
 - **MEM** (*marginal effect at the mean*): efek yang dievaluasi pada $\bar{X} \rightarrow$ margins, `dydx(*) atmeans`
- Untuk *dummy*: laporkan $F(X\beta | d=1) - F(X\beta | d=0)$; Stata melakukan hal ini jika Anda menulis `i.d.`

Perbandingan yang adil

Bandikan **AME** logit, AME probit, dan koefisien LPM: ketiganya memiliki skala yang sama (perubahan probabilitas) dan biasanya **nilainya sangat berdekatan**. Jangan pernah membandingkan koefisien mentah.

Mengapa efeknya tidak konstan: satu gambar



Abu-abu: langkah yang sama dalam X di tiga tempat. **Merah:** kenaikan P yang disebabkan langkah tersebut.

Intuisi: langkah yang sama pada X mengubah probabilitas secara signifikan di sekitar $P \approx 0.5$, namun hampir tidak berpengaruh di dekat 0 atau 1. Mobil dengan bobot 4,000 lbs hampir pasti merupakan produk domestik; penambahan bobot sebesar 100 lbs tidak akan mengubah status tersebut. Itulah sebabnya satu angka (β) tidak bisa dianggap sebagai “efek”-nya, dan mengapa kita menggunakan nilai rata-rata: AME.

Ringkasan: LPM versus logit versus probit

	LPM	Logit	Probit
$P(Y = 1 X)$	$X\beta$	$\Lambda(X\beta)$	$\Phi(X\beta)$
Estimasi	OLS	ML	ML
Prediksi di dalam $[0, 1]$?	tidak	ya	ya
Marginal effect	$= \beta_k$ konstan	$\lambda(X\beta)\beta_k$	$\phi(X\beta)\beta_k$
Interpretasi langsung	perubahan probabilitas	log-odds; $e^\beta = \text{odds ratio}$	indeks laten (dalam SD)
Heteroskedastik?	ya (gunakan robust)	bukan masalah	bukan masalah
Stata	<code>regress</code>	<code>logit, logistic</code>	<code>probit</code>
Kasus	prakiraan cuaca (MOS)	Challenger, BART, Baldus, AMS, VioGén	Bliss, Elo (FIDE)

Saran praktis: untuk mengetahui arah dan signifikansi suatu efek, LPM dengan robust sudah memadai dan mudah dipahami. Untuk **probabilitas prediksi**, serta untuk efek yang bersifat non-linear pada bagian ekor distribusi, gunakan model logit atau probit dan laporkan **margins**.

Kasus 7 — VioGén Spanyol: skor risiko bagi perempuan yang melaporkan kekerasan (2007 –)




Illustration of the headline; not a reproduction of the original page.

Kartu judul yang dibuat untuk dek ini. Kode QR tersebut membuka artikel: A. Satariano dan R. Toll Pifarré, *The New York Times*, 18 Juli 2024.

- Sejak 2007, ketika seorang perempuan melaporkan kekerasan kepada polisi, petugas mengisi kuesioner (35–39 butir) yang mencakup: tingkat keparahan kekerasan di masa lalu, pelaku, kerentanan korban, serta faktor-faktor pemberat.
- Skor ini memprediksi terjadinya **serangan baru**. Butir-butir skor tersebut dipilih dan diberi bobot menggunakan **odds ratios dari regresi logistik**; rumus pastinya belum pernah dipublikasikan. AUC yang dilaporkan: 0.66–0.80.
- Lima tingkat: *dapat diabaikan, rendah, sedang, tinggi, dan ekstrem*. Tingkat yang lebih tinggi mencakup penyediaan tombol panik, pelacakan pelaku, atau penjagaan rumah oleh polisi.
- Sekitar 600,000 kasus telah diproses VioGén hingga 2020.

Kasus 7 — Saat sistem klasifikasi keliru, seseorang bisa meninggal dunia



95% skor dibiarkan sesuai setelan sistem
3% korban dinilai *sedang* atau lebih tinggi

Sumber: Audit eksternal Eticas (2022); *The New York Times* (2024).

Lobna Hemid. Pada 11 Januari 2022 suaminya menyeranginya di rumah mereka di dekat Madrid. Ia melaporkan kejadian tersebut; VioGén mengategorikannya sebagai *risiko rendah*. Tujuh minggu kemudian, suaminya menikamnya hingga tewas.

Januari 2025: Spanyol meluncurkan VioGén 2, yang menghapus tingkat terendah (“tanpa risiko”).

Pembelajaran (yang diukur dalam Bagian II, §6)

- False negative di sini bukanlah sekadar statistik.
- Letak cutoff perlindungan menentukan siapa yang terlindungi.
- AUC 0.7 memeringkat kasus lebih baik daripada kebetulan — belum cukup untuk keputusan seperti ini.
- Petugas jarang mengabaikan skor: *bias otomatisasi*.


Kasus 8 — Algoritma dengan koefisien untuk jenis kelamin perempuan (Austria, 2018)



Sebuah kantor AMS, layanan ketenagakerjaan publik Austria, di Villach.
Foto: Naturpuur, CC BY-SA 4.0.

- **AMS** ingin anggaran pelatihannya jatuh ke tempat yang paling bermanfaat, maka pencari kerja dinilai menurut peluangnya mendapat pekerjaan.
- $Y = 1$: setidaknya 90 hari kerja tanpa subsidi dalam 7 bulan (model kedua: 180 hari dalam 24 bulan).
- X : jenis kelamin, usia, kewarganegaraan, pendidikan, gangguan kesehatan, kewajiban pengasuhan (*dicatat hanya untuk perempuan*), sektor, wilayah, pekerjaan sebelumnya.
- Model: **regresi logistik** — 96 model, menurut hasil, kelompok pencari kerja, dan tahap pengangguran. Presisi dilaporkan 80–91%.
- Keputusan:
 - Kelompok **A**, $\hat{P}(\text{kerja jangka pendek}) \geq 66\%$: sedikit dukungan.
 - Kelompok **C**, $\hat{P}(\text{kerja jangka panjang}) \leq 25\%$: dukungan minim, dirujuk ke tempat lain.
 - Kelompok **B**, sisanya: sebagian besar dana pelatihan.
- Diuji sejak 2018; dilarang Otoritas Perlindungan Data pada 2020. Pengadilan memenangkan AMS pada 2025 — proyeknya sudah mati.

Kasus 8 — Satu koefisien, satu cutoff



Usia, pendidikan, riwayat, dan wilayah yang sama.
 Satu-satunya perbedaan adalah variabel dummy jenis kelamin.

Perhitungannya

- Koefisien untuk female: $\hat{\beta} = -0.14$. Odds ratio $e^{-0.14} = 0.87$: odds seorang perempuan untuk mendapatkan pekerjaan adalah **13% lebih rendah**.
- Seorang pria di $\hat{P} = 0.68$: log-odds $\ln(0.68/0.32) = 0.754$. Perempuan yang sama: $0.754 - 0.14 = 0.614 \Rightarrow \hat{P} = 0.649$.
- Mendekati cutoff:
 $\hat{P}(1 - \hat{P})\hat{\beta} \approx 0.66 \times 0.34 \times (-0.14) = -3.1$ poin — cukup untuk mengubah kelompoknya.

Argumen para kritikus

Koefisien tersebut secara akurat menggambarkan hasil-hasil di masa lalu—termasuk diskriminasi yang pernah terjadi. Menggunakannya untuk mengalokasikan pelatihan mengubah kerugian di masa lalu menjadi kerugian di masa depan.

Bagian II — Dari kasus ke praktik: contoh `auto.dta`

Data tersebut: data mobil 1978 dari Stata, 74 mobil.

- $Y = \text{foreign}$: 1 jika mobil tersebut impor (22 mobil, 29.7%), 0 jika domestik (52 mobil).
- $X = \text{weight}$ (pon) dan mpg (mil per galon).
- Pertanyaan: jenis mobil apa yang kemungkinan besar merupakan mobil impor?

Stata

```
sysuse auto, clear
tab foreign
```

Setiap angka dan grafik di bagian ini berasal dari `stata/auto_logit.do`. Jalankan sendiri.

Apa yang akan kita lakukan, sesuai urutannya:

- 1 Estimasi logit dan baca keluarannya
- 2 Odds ratios
- 3 Probabilitas prediksi
- 4 Marginal effects: AME, MEM, `margins at()`, `marginsplot`
- 5 Interaksi dan variabel faktor
- 6 Seberapa baik modelnya? Klasifikasi, ROC, kalibrasi
- 7 Saat keadaan memburuk
- 8 Standard errors: robust, clustered, survey

1. Mengestimasi logit

```
. logit foreign weight mpg
```

```
Logistic regression           Number of obs =      74
                             LR chi2(2)      =   35.72
                             Prob > chi2     =  0.0000
Log likelihood = -27.175156    Pseudo R2    =  0.3966
```

foreign	Coefficient	Std. err.	z	P> z
weight	-.0039067	.0010116	-3.86	0.000
mpg	-.1685869	.0919175	-1.83	0.067
_cons	13.70837	4.518709	3.03	0.002

Model yang sama, estimator lainnya: probit: -0.0023 , -0.104 (rasio terhadap logit ≈ 1.65). regress: -0.00047 , -0.019 .

Apa yang ditunjukkan oleh koefisien

- $\text{weight} < 0$: mobil yang lebih berat cenderung bukan merupakan kendaraan impor (pada 1978, mobil impor berukuran kecil).
- $\text{mpg} < 0$ *berdasarkan bobot*: di antara mobil dengan bobot yang sama, mobil yang lebih hemat bahan bakar cenderung merupakan produk dalam negeri. Tingkat signifikansinya hanya marjinal ($p = 0.067$).
- Tanda dan nilai p dapat dibaca secara langsung. **Besarannya tidak demikian**: ini adalah log-odds, bukan probabilitas.

1. Membaca output

Item	Arti
Koefisien	Perubahan log-odds untuk perubahan satu unit pada X
Standard error	Variabilitas sampling dari estimasi
$z, P > z $	Uji $H_0: \beta_k = 0$ (uji Wald)
Log likelihood	$\ln L$ pada nilai maksimum; -27.18 di sini; -45.03 untuk model yang hanya memuat konstanta
LR chi2(2)	$2[\ln L - \ln L_0] = 2[-27.18 - (-45.03)] = 35.72$: apakah variabel-variabel penjelas tersebut memperbaiki kecocokan model sama sekali?
Pseudo- R^2	McFadden: $1 - \ln L / \ln L_0 = 1 - 27.18/45.03 = 0.397$

- Uji LR memainkan peran yang sama dengan uji F dalam OLS: uji ini membandingkan dua model *bersarang* berdasarkan nilai log-likelihood-nya.
- Pseudo- R^2 **bukanlah** proporsi varians yang dijelaskan. Gunakan nilai ini hanya untuk membandingkan model pada data yang sama; 0.2–0.4 sudah dianggap sebagai kecocokan yang baik untuk logit.
- Di atas tabel, Stata menampilkan log iterasi dari pencarian ML. Jika proses tersebut tidak konvergen, jangan mengandalkan angka-angka tersebut.

2. Odds ratios: logistic

```
. logistic foreign weight mpg
```

foreign	Odds ratio	Std. err.	z	P> z
weight	.9961009	.0010077	-3.86	0.000
mpg	.8448578	.0776572	-1.83	0.067
_cons	898396.7	4059594	3.03	0.002

Note: _cons estimates baseline odds.

Model sama, z dan p sama; hanya kolomnya yang berbeda: $e^{\hat{\beta}}$ bukan $\hat{\beta}$. logit ..., or juga demikian.

Dua jebakan

Odds bukanlah probabilitas: OR = 2 tidak berarti “kemungkinan dua kali lebih besar”. Selain itu, nilai OR bergantung pada satuan X ; lakukan penyesuaian skala sebelum melakukan interpretasi.

Cara membaca odds ratio

- OR = 1: tidak ada efek. OR = 2: odds menjadi dua kali lipat. OR = 0.8: odds turun sebesar 20%.
- mpg: OR = 0.845. Satu mil per galon tambahan menurunkan odds mobil itu merupakan barang impor sekitar 15%.
- weight: OR = 0.9961 *per pon* — tampaknya tidak berarti apa-apa. Per 100 pon: $0.9961^{100} = e^{100\hat{\beta}} = 0.68$, jadi odds turun sepertiga.


3. Probabilitas prediksi

```
. predict phat
(option pr assumed; Pr(foreign))

. list make foreign weight mpg phat in 1/8
```

make	foreign	weight	mpg	phat
AMC Concord	Domestic	2,930	22	.19044
AMC Pacer	Domestic	3,350	17	.09578
AMC Spirit	Domestic	2,640	22	.42208
Buick Century	Domestic	3,250	20	.08626
Buick Electra	Domestic	4,080	15	.00849
Buick LeSabre	Domestic	3,670	18	.02499
Buick Opel	Domestic	2,230	26	.64866
Buick Regal	Domestic	3,280	20	.07746

phat merupakan $\hat{P}(Y = 1 | X_i) = \Lambda(X_i\hat{\beta})$ bagi setiap mobil. Buick Opel, yang ringan dan hemat bahan bakar, “diprediksi” sebagai produk impor (0.65). Faktanya, mobil ini diproduksi oleh Opel di Jerman dan dijual dengan merek Buick.



Lingkaran abu-abu: data 0/1. Titik merah: phat untuk setiap mobil — tersebar karena setiap mobil memiliki nilai mpg tersendiri. Kurva biru: S-curve logit dengan mpg dijaga pada nilai rata-ratanya (21.3).

4. Marginal effects: AME dan MEM

$$\text{AME} = \frac{1}{N} \sum_{i=1}^N f(X_i \hat{\beta}) \hat{\beta}_k \quad \text{MEM} = f(\bar{X} \hat{\beta}) \hat{\beta}_k$$

- **AME** merata-ratakan efek atas sampel yang ada. Laporkan ini.
- **MEM** mengevaluasinya pada “mobil rata-rata”, yang mungkin tidak ada.
- Standard errors: *metode delta*.

Dampak terhadap $P(\text{foreign})$	weight	mpg
Logit AME	-0.000457	-0.0197
Logit MEM	-0.000518	-0.0224
Probit AME	-0.000465	-0.0207
LPM (robust)	-0.000468	-0.0194

```
. margins, dydx(*)
Average marginal effects
```

	dy/dx	std. err.	z	P> z
weight	-.0004569	.0000571	-8.01	0.000
mpg	-.0197187	.0096987	-2.03	0.042

```
. margins, dydx(*) atmeans
Conditional marginal effects
At: weight = 3019.459 (mean), mpg = 21.2973 (mean)
```

	dy/dx	std. err.	z	P> z
weight	-.0005179	.0001389	-3.73	0.000
mpg	-.0223512	.0127037	-1.76	0.079

Perhatikan ini: tambahan 100 pon menurunkan probabilitas menjadi mobil impor sekitar 4.6 poin, secara rata-rata. Dan dua baris terakhir tabel tersebut: AME probit dan LPM menunjukkan hasil yang sama—klaim mengenai “perbandingan yang adil” pun terverifikasi.

4. Efek pada nilai-nilai yang dipilih: margins, at() dan marginsplot


```
. margins, at(weight=(2000(500)4500))
```

```
Predictive margins
```

	Margin	std. err.	z	P> z
weight=2000	.8768344	.0561661	15.61	0.000
weight=2500	.5823404	.0919699	6.33	0.000
weight=3000	.2038047	.0692124	2.94	0.003
weight=3500	.0384522	.0259707	1.48	0.139
weight=4000	.005745	.0064102	0.90	0.370
weight=4500	.000821	.0013048	0.63	0.529

```
. marginsplot
```

- Mobil seberat 2,000 lb: peluang 88% sebagai kendaraan impor. 3,000 lbs: 20%. 4,000 lbs: di bawah 1%.
- Dari 2,500 ke 3,000 lbs, probabilitasnya turun 38 poin; dari 4,000 ke 4,500, turun setengah poin. **Itulah** marginal effect yang tidak konstan—dan at() memungkinkan Anda mengevaluasi skenario apa pun, bukan hanya nilai rata-ratanya.



marginsplot: probabilitas prediksi dengan pita kepercayaan 95%.

5. Variabel faktor, interaksi, dan apa yang dihitung oleh margins

Notasi

- `i.sex` kategorikal, `c.age` kontinu, `#` interaksi, `##` efek utama ditambah interaksi.
- Untuk dummy yang dideklarasikan dengan `i.`, `margins` melaporkan **perubahan diskret** $F(X\beta \mid d=1) - F(X\beta \mid d=0)$, bukan turunan.

Dua jenis margin

- **Bersyarat:** setiap regresor bersifat tetap (misalnya `atmeans`).
- **Prediktif:** regresor yang disebut ditahan, sisanya mengikuti data, lalu dirata-ratakan (default).

Aspek praktis: sel-sel kosong dalam `sex#group` menyebabkan nilai marginal *tidak dapat diestimasi*.

```
. logit foreign c.weight##c.mpg
```

foreign	Coefficient	Std. err.	z	P> z
weight	-.0010199	.0024909	-0.41	0.682
mpg	.1712339	.2994853	0.57	0.567
c.weight#c.mpg				
c.mpg	-.0001637	.00014	-1.17	0.242
_cons	7.829103	6.332902	1.24	0.216

```
. margins, dydx(weight) at(mpg=(15 20 25 30))
```

	dy/dx	std. err.	z	P> z
mpg=15	-.0003716	.0000202	-18.35	0.000
mpg=20	-.000351	2.92e-06	-120.26	0.000
mpg=25	-.0003605	9.97e-06	-36.16	0.000
mpg=30	-.0003897	.0000466	-8.36	0.000

Dengan interaksi, koefisien individual kehilangan makna (semuanya “tidak signifikan” di sini), namun **pengaruh bobot pada tiap tingkat mpg** presisi. Selalu lewat `margins`.

6. Seberapa baik modelnya? (a) Tabel klasifikasi

Prediksi $\hat{Y} = 1$ jika $\hat{P} \geq c$ (cutoff default $c = 0.5$), lalu lakukan tabulasi silang terhadap data sebenarnya:

	Prediksi 1	Prediksi 0
Aktual 1	TP (true positive)	FN (false negative)
Aktual 0	FP (false positive)	TN (true negative)

- **Sensitivitas** = $TP / (TP + FN)$: dari impor yang sebenarnya, berapa banyak yang berhasil kita deteksi?
- **Spesifisitas** = $TN / (TN + FP)$: dari kasus domestik yang sebenarnya, berapa banyak yang tidak kita ganggu?
- **Akurasi** = $(TP + TN) / N$.

```
. estat classification
```

Classified	True		Total
	D	~D	
+	13	6	19
-	9	46	55
Total	22	52	74

```
Classified + if predicted Pr(D) >= .5
```

Sensitivity	Pr(+ D)	59.09%
Specificity	Pr(- ~D)	88.46%
Positive predictive value	Pr(D +)	68.42%
Negative predictive value	Pr(~D -)	83.64%
Correctly classified		79.73%

Akurasi 80% terdengar bagus—namun sekadar melabeli setiap mobil sebagai “domestik” saja sudah menghasilkan skor 70%. Model tersebut hanya menangkap 13 dari 22 mobil impor.

6. Seberapa baik modelnya? (b) Pertukaran nilai cutoff

Cutoff c	Aturan	Sens.	Spes.
1.0	prediksi 0 untuk semua	0	1
0.8	hanya $\hat{P} > 0.8$ jadi 1	rendah	tinggi
0.5	default biasa	sedang	sedang
0.3	lebih longgar untuk 1	tinggi	rendah
0.0	prediksi 1 untuk semua	1	0

- Menurunkan c berarti lebih banyak 1 yang diprediksi: sensitivitas $\uparrow$, spesifisitas $\downarrow$. Tidak ada yang gratis.
- c yang tepat bergantung pada **biaya dari setiap kesalahan**: meloloskan pinjaman yang mengandung unsur penipuan tidak sama dengan membuat nasabah yang jujur merasa terganggu.
- Untuk auto, $c = 0.3$ menangkap 18 dari 22 mobil impor dengan konsekuensi 12 alarm palsu.


```
. estat classification, cutoff(0.3)
```

Classified	True		Total
	D	~D	
+	18	12	30
-	4	40	44
Total	22	52	74

```
Classified + if predicted Pr(D) >= .3
```

Sensitivity	Pr (+ D)	81.82%
Specificity	Pr (- ~D)	76.92%
Correctly classified		78.38%

6. Seberapa baik modelnya? (c) Kurva ROC, AUC, dan kalibrasi



`lroc: sensitivitas terhadap 1—spesifisitas untuk setiap cutoff dari 1 hingga 0. Area di bawah kurva = 0.893.`

ROC memetakan keseluruhan trade-off dari slide sebelumnya ke dalam satu kurva. **AUC** merangkumnya menjadi satu angka: probabilitas bahwa mobil impor yang dipilih secara acak memiliki $\hat{P}$ lebih tinggi dibandingkan mobil domestik yang dipilih secara acak.

AUC	Discrimination
0.50	none (a coin toss)
0.60–0.70	poor
0.70–0.80	acceptable
0.80–0.90	good ← auto: 0.89
0.90–1.00	excellent

Kalibrasi merupakan persoalan yang berbeda: apakah probabilitas yang diprediksi *sudah tepat*, bukan sekadar terurut dengan baik? `estat gof, group(10)` (Hosmer–Lemeshow): $\chi^2(8) = 2.30$, $p = 0.97$ — tidak ada bukti ketidaksesuaian model (misfit).

7. Saat segalanya tidak berjalan lancar

```
. logit foreign i.rep78
```

```
note: 1.rep78 != 0 predicts failure perfectly;
      1.rep78 omitted and 2 obs not used.
note: 2.rep78 != 0 predicts failure perfectly;
      2.rep78 omitted and 8 obs not used.
note: 5.rep78 omitted because of collinearity.
```

```
Logistic regression              Number of obs =      59
```

foreign	Coefficient	Std. err.	z	P> z
-----+-----				
rep78				
1	0 (empty)			
2	0 (empty)			
3	-3.701302	.9906975	-3.74	0.000
4	-1.504077	.9128709	-1.65	0.099
5	0 (omitted)			
_cons	1.504077	.781736	1.92	0.054
-----+-----				

Prediksi sempurna (pemisahan)

- Setiap mobil dengan catatan perbaikan 1 atau 2 adalah mobil domestik. Estimasi ML adalah $-\infty$; Stata mengabaikan kategori tersebut beserta observasinya. Bacalah catatannya.
- Solusi: gabungkan kategori yang jarang, hapus variabel tersebut, atau gunakan logit terpenalisasi (firthlogit).

Kolinearitas: seperti halnya pada OLS, variabel yang redundan dihilangkan (dalam hal ini 5.rep78, setelah 1 dan 2 dihapus).

Kegagalan konvergensi: “tidak cekung” (not concave), “macet” (backed up), “konvergensi tidak tercapai” — terlalu banyak parameter untuk data yang tersedia, regresor yang nilainya hampir konstan, atau masalah skala. Sederhanakan; periksa summarize; sesuaikan skala.

8. Standard errors: robust, clustered, survey

Stata

```
logit foreign weight mpg, vce(robust)
logit foreign weight mpg, vce(cluster rep78)

svyset psu [pweight=w], strata(strata)
svy: logit y x1 x2
```

- `vce(robust)`: tidak berbahaya dan merupakan prosedur standar, meskipun solusinya tidak sekuat pada OLS—jika model logit mengalami kesalahan spesifikasi, estimasi titiknya pun akan menjadi tidak akurat.
- `vce(cluster var)`: observasi di dalam suatu desa, perusahaan, atau sekolah saling berkorelasi. Diperlukan jumlah klaster yang memadai: 5 (dalam kasus ini) terlalu sedikit; 30 hingga 50 merupakan pedoman praktis yang umum digunakan.
- `svy`: bobot, strata, dan PSU dari survei kompleks (Susenas, Sakernas, IFLS, DHS). Tanpa hal tersebut, nilai standard error menjadi keliru.

Standard error mpg	default	robust	cluster
nilai	0.092	0.112	0.027
z	-1.83	-1.51	-5.62
p	0.067	0.131	0.000

Koefisien yang sama (-0.169) pada ketiga kolom. Clustered SE merupakan peringatan, bukan hasil: dengan klaster 5 sifat asimtotik yang mendasarinya belum mulai bekerja. Jangan pernah memilih kolom dengan p terkecil.

Melampaui logit biner

Situasi	Stata	Ide
Tiga pilihan atau lebih, tak berurutan	<code>mlogit</code>	Model McFadden untuk J alternatif (kuliah depan)
Kategori berurutan	<code>ologit</code> , <code>oprobit</code>	Satu indeks laten, beberapa ambang (kuliah depan)
Data panel	<code>xtlogit</code>	Efek tetap atau acak, observasi berulang
Data berkelompok / bertingkat	<code>meologit</code>	Intersep acak: desa, sekolah, perusahaan
Peristiwa langka, hubungan asimetris	<code>cloglog</code>	Log-log komplementer
Banyak kandidat regresor	<code>lasso logit</code>	Seleksi yang dikenai penalti
Prediksi yang sempurna	<code>firthlogit</code>	Likelihood terpenalisasi (buatan pengguna)

Semuanya merupakan S-curve yang sama dengan struktur tambahan di sekelilingnya. Jika Anda memahami logit dan margins, berarti Anda memahami sebagian besar dari masing-masing hal tersebut.

Latihan praktik langsung

Dataset: `sysuse auto`. Tambahkan `length` ke model.

Tugas

- ➊ `logit foreign weight mpg length` — tanda mana yang berubah, dan nilai *p* mana yang berubah? Mengapa `length` dan `weight` bisa saling bertentangan?
- ➋ `logistic ...` — laporkan odds ratio `length` per 10 inci.
- ➌ `margins, dydx(*)` — variabel mana yang memiliki pengaruh terbesar terhadap *probabilitas*? Bandingkan dengan LPM.
- ➍ `margins, at(length=(140(20)240))` dan `marginsplot`.
- ➎ `estat classification` pada cutoffs 0.5 dan 0.3; `lroc`. Apakah AUC meningkat pada 0.893?
- ➏ Jalankan ulang menggunakan `probit`. Pastikan rasio koefisiennya berada di kisaran 1.6–1.7 dan nilai AME-nya hampir identik.

Untuk didiskusikan: model tersebut mengklasifikasikan Buick Opel 1978 sebagai kendaraan impor. Apakah ini kesalahan model atau kesalahan pelabelan?

Kesalahan umum

- 1 Menafsirkan koefisien logit sebagai perubahan probabilitas. Hal ini merupakan perubahan dalam log-odds; gunakan `margins`.
- 2 Menafsirkan odds ratio sebagai rasio probabilitas (“dua kali lebih mungkin”).
- 3 Membandingkan koefisien mentah antar-model logit, probit dan LPM —atau antar-sampel. Bandingkan AME.
- 4 Mengabaikan catatan yang menyebutkan bahwa hal itu “memprediksi kegagalan dengan sempurna”.
- 5 Melaporkan akurasi saja saat kejadian (outcome) jarang terjadi: akurasi 95% tidak bermakna jika 95% datanya bernilai nol. Laporkan sensitivitas, spesifisitas, AUC.
- 6 Terlalu banyak dummies untuk sampel kecil: pemisahan (separation) dan standard errors yang sangat besar.
- 7 Standard errors terkluster dengan jumlah kluster yang sedikit.
- 8 Mengabaikan `svy`: pada data survei.
- 9 Tidak menggunakan LPM karena alasan prinsip. Dalam sebuah eksperimen, atau untuk melihat sekilas arah dan signifikansinya, hal itu dapat diterima—dengan `robust`.

Delapan kasus, delapan pelajaran

Bliss	Data nol-satu membentuk S-curve. Di baliknya terdapat latent variable dengan ambang batas.
Hujan 70%	LPM itu nyata dan berguna; kelemahannya (prediksi di luar $[0, 1]$, heteroskedastisitas) sudah dikenal dan dapat diterima.
Challenger	Sesuaikan kurva dengan <i>seluruh</i> data. Jangan pernah memilih sampel berdasarkan Y . Lakukan ekstrapolasi dengan mata terbuka.
Elo	Probit dan logit hampir selalu memberikan jawaban yang sama; $\beta_{\text{logit}} \approx 1.6 \beta_{\text{probit}}$.
McFadden	Model logit diturunkan dari prinsip maksimisasi utilitas, sehingga mampu memprediksi pilihan yang belum pernah ditawarkan sebelumnya.
McCleskey	Odds ratio menggambarkan populasi, bukan individu; variabel kontrolnya tidak pernah lengkap.
VioGén	Kesalahan pengklasifikasi menimbulkan korban. Tentukan cutoff berdasarkan konsekuensi dari setiap kesalahan; skor tidak boleh menggantikan pertimbangan.
AMS	Koefisien pada variabel dummy kelompok berlaku bagi setiap orang dalam kelompok tersebut; di dekat cutoff, selisih beberapa poin menentukan siapa yang mendapatkan bantuan.

Kuliah berikutnya: lebih dari dua alternatif — `mlogit` (pengenalan tulisan tangan) dan `oprobit`.

Referensi (1/2): Kasus 1–6 dan buku-buku teks

- Bliss, C. I. (1934). “The method of probits.” *Science* 79(2037): 38–39.
- Dalal, S. R., Fowlkes, E. B., & Hoadley, B. (1989). “Risk Analysis of the Space Shuttle: Pre-Challenger Prediction of Failure.” *JASA* 84(408): 945–957.
- Glahn, H. R., & Lowry, D. A. (1972). “The use of Model Output Statistics (MOS) in objective weather forecasting.” *J. Applied Meteorology* 11: 1203–1211.
- Elo, A. E. (1978). *The Rating of Chessplayers, Past and Present*. Arco.
- McFadden, D. (1974). “Conditional logit analysis of qualitative choice behavior.” In P. Zarembka (ed.), *Frontiers in Econometrics*. Academic Press. — Nobel Lecture (2000): “Economic Choices.”
- Baldus, D. C., Woodworth, G., & Pulaski, C. A. (1990). *Equal Justice and the Death Penalty*. Northeastern Univ. Press. — *McCleskey v. Kemp*, 481 U.S. 279 (1987).
- Wooldridge, J. M. *Introductory Econometrics*, Sections 7.5 (LPM) and 17.1 (logit/probit).
- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*, Section 3.4.2 (a defence of the LPM).
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*, 3rd ed. Wiley.
- Long, J. S., & Freese, J. (2014). *Regression Models for Categorical Dependent Variables Using Stata*, 3rd ed. Stata Press.
- StataCorp. *Stata Base Reference Manual*. [R] logit, [R] logistic, [R] margins, [R] estat classification, [R] lroc.

Referensi (2/2): Kasus 7 dan 8

- López-Ossorio, J. J., et al. (2019). "Validation and calibration of the Spanish police intimate partner violence risk assessment system (VioGén)." *Journal of Police and Criminal Psychology*.
- López-Ossorio, J. J., et al. (2021). "Intimate partner homicide risk assessment by police in Spain: the dual protocol VPR5.0-H." *Psychosocial Intervention*.
- Eticas Foundation (2022). *The External Audit of the VioGén System*.
- Satariano, A., & Toll Pifarré, R. (2024). "An Algorithm Told Police She Was Safe. Then Her Husband Killed Her." *The New York Times*, 18 July.
- Allhutter, D., et al. (2020). "Algorithmic profiling of job seekers in Austria: How austerity politics are made effective." *Frontiers in Big Data* 3: 5.

Lampiran: data *Challenger* (Dalal dkk. 1989)

Misi	°F	damage	Misi	°F	damage	Misi	°F	damage
STS-1	66	0	41-B	57	1	51-G	70	0
STS-2	70	1	41-C	63	1	51-F	81	0
STS-3	69	0	41-D	70	1	51-I	76	0
STS-5	68	0	41-G	78	0	51-J	79	0
STS-6	67	0	51-A	67	0	61-A	75	1
STS-7	72	0	51-C	53	1	61-B	76	0
STS-8	73	0	51-D	67	0	61-C	58	1
STS-9	70	0	51-B	75	0	51-L	31	?

damage = 1 jika terdapat *kerusakan akibat panas* (erosi atau blow-by) pada O-ring sambungan lapangan (field-joint). Data STS-4 tidak tersedia (booster hilang di laut). Grafik “jumlah insiden” pada slide sebelumnya menggunakan jumlah sambungan (dari total 6) yang terdampak.