

Multinomial Logit, Conditional Logit, dan Ordered Probit/Logit

Dengan aplikasi Stata

Arief Anshory Yusuf

Mata Kuliah: Mikroekonometrika

October 2, 2026



Setiap hari, Anda memilih

- Ponsel mana yang sebaiknya dibeli.
- Video mana yang akan ditonton selanjutnya.
- Jalan mana yang harus diambil untuk menuju kampus?

Dan setiap hari, hal-hal terjadi padamu saat berada di atas tangga:

- sedikit sakit, sakit parah, di rumah sakit;
- tidak setuju, netral, setuju;
- miskin, menengah, kaya.

Mata kuliah ini

Statistik yang menjelaskan dan memprediksi **pilihan di antara berbagai opsi**, serta **posisi pada suatu jenjang**. Hari ini, tidak ada rumus. Hanya lima kisah nyata tentang apa yang terjadi saat orang-orang menggunakannya.

Lima kisah nyata

Kasus	Pertanyaan	Apa yang dipertaruhkan	Model
1 Penjudi di Hong Kong, 1985	Kuda mana yang akan menang?	hampir US\$1 miliar	conditional logit
2 <i>Apple v. Samsung</i> , 2014	Berapa nilai satu fitur?	klaim US\$2.2 miliar	conditional logit
3 YouTube, 2016	Video mana yang Anda tonton?	70% waktu tonton	conditional logit
4 Remdesivir, 2020	Apakah pasien membaik?	obat COVID-19 pertama	ordered logit
5 MR CLEAN, 2014	Apakah pasien stroke pulih?	perawatan stroke global	ordered logit

Dalam kasus 1–3, orang-orang **memilih satu opsi di antara banyak pilihan**.

Dalam kasus 4–5, pasien berada **di suatu titik pada sebuah tangga**, mulai dari kondisi sehat hingga meninggal dunia.

Kasus 1. Penjudi yang mengalahkan arena pacuan kuda



Arena Balap Kuda Happy Valley, Hong Kong. Foto: TypeZero, CC BY-SA 4.0, Wikimedia Commons.

- **Bill Benter** adalah seorang penghitung kartu. Kasino-kasino di Las Vegas melarangnya masuk.
- Pada **tahun 1985**, ia terbang ke Hong Kong dengan membawa tiga komputer IBM di dalam bagasinya.
- Ia menemukan sebuah makalah akademis tentang prediksi pacuan kuda. Ia membuat versinya sendiri dan memasukkan segala macam data ke dalamnya: riwayat balapan, bobot, joki, gerbang start, dan lintasan. Lebih dari **120 fakta mengenai setiap kuda**.
- Modelnya memberikan **peluang menang** bagi setiap kuda. Ia hanya memasang taruhan ketika odds yang ditetapkan oleh publik keliru.

Sumber: K. Chellel, "The gambler who cracked the horse-racing code", *Bloomberg Businessweek*, Mei 2018.

Kasus 1. Apa yang terjadi

US\$3 m

dimenangkan dalam satu musim,
1990–91

≈ US\$1 bn

sepanjang kariernya, sebagaimana
dilaporkan oleh *Bloomberg*

2%

dari seluruh kegiatan taruhan di
Hong Kong, yang dilakukan oleh
sindikatan mitranya saja

- **Kejutan tak terduganya adalah:** model miliknya sendiri hanya menghasilkan keuntungan kecil. Keuntungan besar baru diperoleh saat ia membiarkan model tersebut **belajar dari orang banyak** juga—yakni dengan menggabungkan 120 fakta temuannya dengan odds taruhan dari pihak-pihak lain.
- **Reaksinya.** Hong Kong Jockey Club mulai memublikasikan lebih banyak datanya, sehingga para petaruh biasa dapat melihat apa yang dilihat oleh tim-tim komputer tersebut.

Model: conditional logit

Setiap kuda memperoleh **skor** berdasarkan faktor-faktornya: performa, bobot, joki, dan posisi start (gate). Bobot penilaian yang sama diterapkan pada setiap kuda; hanya faktor-faktornya yang berbeda. Model ini mengubah skor kuda-kuda dalam suatu perlombaan menjadi **peluang menang yang totalnya berjumlah 100%**. Semakin tinggi skor seekor kuda dibandingkan dengan para pesaingnya, semakin besar pula peluang kemenangannya.

Pertanyaan untuk Anda

Kapan Anda akan lebih memercayai model Anda sendiri dibandingkan pendapat orang banyak?

Kasus 2. *Apple vs. Samsung*: berapa nilai “geser untuk membuka kunci”?



Samsung Galaxy S6 edge dan Apple iPhone 6. Foto: Maurizio Pesce, CC BY 2.0, Wikimedia Commons.

- Pada tahun 2014, di sebuah pengadilan federal di **San Jose, California**, Apple menyatakan bahwa Samsung meniru lima fitur iPhone, di antaranya **slide to unlock**, **pencarian universal**, dan **koreksi otomatis**.
- Pertanyaan sulit bagi juri: tidak ada orang yang membeli fitur “geser untuk membuka kunci” secara terpisah. **Berapakah nilai uang dari satu fitur kecil tersebut?**
- Ahli dari Apple, Profesor **John Hauser** dari MIT, memperlihatkan sejumlah model ponsel 1 000 kepada para pemilik ponsel dan tablet, lalu bertanya: *mana yang akan Anda beli?*
- Berdasarkan pilihan mereka, ia menghitung nilai setiap fitur bagi pembeli.

Sumber: CNBC dan NBC News, 2 Mei 2014; Recode, 22 April 2014.

Kasus 2. Apa yang terjadi

US\$2.2 bn

apa yang diminta Apple

\$32–\$102

tambahan yang bersedia dibayar
pembeli untuk fitur-fitur itu,
menurut pakar Apple

US\$120 m

jumlah yang diputuskan oleh juri:
sekitar 5% dari nilai tuntutan

- **Perdebatannya soal metode.** Para ahli Samsung menyebut survei itu seperti “memilih mobil dari tempat gelasnya”: survei membuat orang memperhatikan fitur yang tak pernah mereka pedulikan.
- **Sejak itu**, survei sejenis menentukan banyak gugatan konsumen di AS: bila label berbohong (“100% alami”), berapa kelebihan bayar pembeli?

Model: conditional logit (survei “conjoint”)

Setiap ponsel imajiner mendapatkan **skor** berdasarkan fitur dan harganya. Orang cenderung memilih ponsel dengan skor yang lebih tinggi. Jika penambahan fitur slide-to-unlock meningkatkan skor sebesar penurunan harga \$50, maka fitur slide-to-unlock tersebut **bernilai \$50** bagi pembeli.

Pertanyaan untuk Anda

Bagaimana mengetahui berapa yang bersedia dibayar orang *lain* untuk face unlock, tanpa sekadar bertanya kepada mereka?

Kasus 3. YouTube: siapa yang memilih video terakhir yang Anda tonton?



Kantor pusat YouTube, San Bruno, California. Foto: BrokenSphere, CC BY 3.0, Wikimedia Commons.

- Setiap menit, orang mengunggah sekitar **400 jam** video baru ke YouTube.
- Untuk kita masing-masing, YouTube harus memilih segelintir video dari **jutaan video** dalam sepersekian detik.
- Pada **tahun 2016**, tiga insinyur Google memublikasikan cara mereka melakukannya. Intinya adalah sebuah model yang memberikan nilai **probabilitas bagi setiap video mengenai kemungkinan Anda akan menontonnya berikutnya**.
- Ini adalah jenis model yang sama dengan yang dikembangkan oleh seorang ekonom pada tahun 1970-an untuk memprediksi apakah para penglaju di San Francisco akan menggunakan kereta baru. Ekonom tersebut, **Daniel McFadden**, memenangkan Hadiah Nobel pada tahun 2000.

Sumber: Covington, Adams & Sargin, "Deep Neural Networks for YouTube Recommendations", 2016; Tubefilter dan CNET, Januari 2018.

Kasus 3. Apa yang terjadi

70%

dari total waktu tonton di YouTube berasal dari rekomendasinya (2018)

400 h

video yang diunggah setiap menit

1972

tahun saat gagasan yang sama pertama kali memprediksi jumlah penumpang kereta

- **Kekhawatirannya adalah ini:** para jurnalis dan peneliti menyalahkan sistem yang sama karena telah menyeret penonton masuk ke dalam “lubang kelinci”—istilah untuk terjebak dalam rangkaian video yang kian ekstrem. Model pilihan pada dasarnya juga merupakan model yang *membentuk* pilihan itu sendiri.
- **Kejutannya adalah:** sebuah teknik yang dipublikasikan oleh McFadden pada tahun 1978 untuk menangani terlalu banyak pilihan ditemukan kembali oleh para insinyur YouTube pada tahun 2019. Kini, teknik tersebut telah menjadi standar dalam industri.

Model: conditional logit (insinyur menyebutnya “softmax”)

Setiap video mendapatkan **skor** berdasarkan tingkat kecocokannya dengan Anda: riwayat Anda, penelusuran Anda, serta profil video itu sendiri. Model ini mengubah jutaan skor tersebut menjadi **nilai peluang yang totalnya 100%**, lalu menampilkan video-video dengan peluang tertinggi kepada Anda.

Pertanyaan untuk Anda

Dari tiga video terakhir yang Anda tonton, berapa banyak yang *Anda* pilih?

Kasus 4. Remdesivir: obat COVID-19 pertama



Oval Office, 29 April 2020. Dr. Anthony Fauci, paling kiri. Foto resmi Gedung Putih karya Shealah Craighead, domain publik.

Sumber: NPR dan CNBC, 29 April 2020; Beigel dkk., *New England Journal of Medicine*, 2020.

- **Musim semi 2020.** Rumah sakit penuh. Tidak ada obat untuk COVID-19.
- Pemerintah AS menguji obat **remdesivir** pada 1 000 pasien rumah sakit di berbagai negara.
- **29 April 2020, Oval Office.** Dr. Anthony Fauci mengumumkan:
Data menunjukkan bahwa remdesivir memiliki efek positif yang nyata dan signifikan dalam mempercepat waktu pemulihan.
- **Dua hari kemudian**, obat tersebut diizinkan untuk penggunaan darurat di Amerika Serikat.

Kasus 4. Apa yang terjadi

Bagaimana Anda mengukur “menjadi lebih baik”?

Sebuah **tangga dengan delapan anak tangga**:

- 1 Di rumah, tanpa batas
- 2 Di rumah, dengan pembatasan atau oksigen
- 3 Di rumah sakit, tidak ada oksigen, tidak ada perawatan
- 4 Di rumah sakit, tanpa oksigen, mendapat sedikit perawatan
- 5 Dirawat di rumah sakit dan menggunakan bantuan oksigen
- 6 Oksigen aliran tinggi
- 7 Menggunakan ventilator
- 8 Mati

Model: ordered logit

Bayangkan kondisi kesehatan setiap pasien sebagai sebuah tombol putar tersembunyi. Kedelapan tahapan tersebut merupakan **titik batas** pada tombol itu. Obat tersebut memutar tombol setiap orang dengan besaran yang sama, dan model ini memperkirakan besaran putaran tersebut. Hasilnya: pasien yang menerima pengobatan memiliki **odds 1.5 kali lebih besar** untuk berada pada tahapan tertentu atau tahapan yang lebih baik.


Pertanyaan untuk Anda

Dua uji coba besar, dua jawaban. Mungkinkah keduanya benar?

Linimasa, 2020

- **2 April**: di tengah uji coba, ukuran utama beralih dari skala tangga ke “jumlah hari hingga pulih”.
- **29 April**: pengumuman. **1 Mei**: penggunaan darurat. **22 Oktober**: persetujuan penuh AS.
- **16 Okt** ∴ uji coba WHO (pasien 11 000): “sedikit atau tidak ada dampak” terhadap kematian. **20 Nov** ∴ WHO menyarankan untuk tidak menggunakannya.

Kasus 5. MR CLEAN: uji klinis yang mengubah penanganan stroke



Plak di Klinikum Stuttgart, Jerman: kasus stroke pertama yang ditangani dengan stent retriever, 3 Maret 2008. Foto: HelixUnwinding, CC BY-SA 4.0, Wikimedia Commons.

- Stroke menyumbat arteri di otak. Setiap menit, sel-sel otak mati.
- Sebuah perangkat baru, yaitu **stent retriever**, bergerak naik melalui pembuluh darah dan **menarik keluar gumpalan darah tersebut**.
- Uji coba sebelumnya untuk mengangkat gumpalan darah telah **gagal**. Banyak dokter telah menyerah.
- **2014, Belanda**. Uji coba MR CLEAN menangani 500 pasien di 16 rumah sakit.
- Metode ini mengukur pemulihan menggunakan **skala tujuh tingkat**, mulai dari “tanpa gejala” hingga “meninggal”, serta memberikan penilaian atas **setiap tingkat** kemajuan yang dicapai pasien, bukan hanya untuk pemulihan total.

Sumber: Berkhemer dkk., *New England Journal of Medicine*, 2015; NeuroNews, “Ten years of MR CLEAN”.

Kasus 5. Apa yang terjadi

33% v 19%

dapat hidup mandiri: dengan vs.
tanpa pengobatan

4 uji coba

dihentikan lebih awal pada
bulan-bulan berikutnya, karena
manfaatnya jelas

1 dari 2.6

pasien yang diobati berakhir
setidaknya satu tahapan lebih
ringan disabilitasnya

- **2015.** Pedoman penanganan stroke disusun ulang. Prosedur pengangkatan bekuan darah menjadi standar perawatan.
- **Mengapa tangganya penting.** Pasien yang beralih dari “terbaring” menjadi “berjalan dengan bantuan” belum “pulih”, tetapi hidupnya berubah. Menghitung setiap tahapan membuat hal itu terlihat.


Model: ordered logit

Alih-alih bertanya “sembuh atau tidak?”, model ini melihat **ketujuh tahapan sekaligus**. Ia mencari satu pergeseran yang paling baik menjelaskan mengapa kelompok yang diobati berada lebih tinggi di tangga daripada yang tidak. Hasil: pasien yang diobati memiliki **odds 1.67 kali lebih besar** untuk berada pada tahapan mana pun atau yang lebih baik.

Pertanyaan untuk Anda

Jika Anda hanya bisa bertanya “sembuh: ya atau tidak?”, pasien mana yang akan menjadi tak terlihat?

Gagasan yang sama, lima puluh tahun dampak



Memilih satu opsi di antara banyak pilihan

Kuda, telepon, video, kereta api, pekerjaan, pesta.

Conditional logit ketika kita mengetahui fakta mengenai *pilihan-pilihan yang ada* (harga, kecepatan, bentuk).

Multinomial logit ketika kita hanya mengetahui fakta mengenai *pihak yang memilih* (usia, pendapatan, pendidikan).

Mendarat di atas tangga


Penyakit, disabilitas, kepuasan, peringkat kredit, nilai ujian.

Ordered logit atau **ordered probit**: satu tombol kendali tersembunyi, beberapa titik potong.

Dalam beberapa minggu mendatang, Anda akan belajar membangun model-model ini sendiri menggunakan Stata dan data nyata.

Bisakah komputer mengenali huruf A, B, dan C *beresolusi rendah* ini?

Setiap gambar di bawah ini adalah huruf A, B, atau C tulisan tangan beresolusi rendah (3×3 piksel). Bisakah komputer menebak huruf tersebut dengan benar?



Pertanyaan: Bisakah model statistik mengenali pola pada piksel-piksel ini dan menentukan hurufnya?

Studi Kasus: Huruf Tulisan Tangan (A, B, C)

Setiap citra huruf direpresentasikan oleh 9 piksel (3×3), dengan 1 = gelap dan 0 = terang. Tiga variasi untuk setiap huruf memperlihatkan *variasi* alami pada tulisan tangan.

A

A₁



$$x = [1, 0, 1, 1, 1, 1, 1, 0, 1]$$

A₂



$$x = [0, 1, 0, 1, 1, 1, 1, 0, 1]$$

A₃



$$x = [1, 0, 1, 1, 1, 1, 1, 1, 1]$$

B

B₁



$$x = [1, 1, 0, 1, 1, 1, 1, 1, 0]$$

B₂



$$x = [1, 1, 0, 1, 1, 0, 1, 1, 0]$$

B₃



$$x = [1, 1, 1, 1, 1, 1, 1, 1, 0]$$

C

C₁



$$x = [0, 1, 1, 1, 0, 0, 0, 1, 1]$$

C₂



$$x = [0, 1, 1, 1, 0, 0, 1, 1, 1]$$

C₃



$$x = [1, 1, 1, 1, 0, 0, 1, 1, 1]$$

Struktur Data: Setiap Gambar Menjadi Satu Observasi

Setiap citra huruf direpresentasikan sebagai 9 variabel biner ($x_1 - x_9$), yang masing-masing bersesuaian dengan satu piksel pada kisi 3×3 . Satu baris data mendeskripsikan satu citra tulisan tangan.

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	Huruf (y)
1	0	1	1	1	1	1	0	1	A
1	1	0	1	1	1	1	1	0	B
0	1	1	1	0	0	0	1	1	C
1	0	1	1	1	0	1	0	1	A
1	1	0	1	1	0	1	1	0	B

- Setiap variabel x_i menunjukkan status piksel (1 = gelap, 0 = terang).
- Variabel dependen y adalah label huruf: A, B, atau C.
- Dataset tersebut memuat 9 variabel independen + 1 variabel dependen $\rightarrow$ yang digunakan dalam estimasi mlogit.

Contoh Pengerjaan Multinomial Logit (1/3)

Tujuan: Menghitung probabilitas huruf *A*, *B*, dan *C* berdasarkan tiga variabel penjelas.

Data yang diamati:

$$x_1 = 2, \quad x_2 = 1, \quad x_3 = 3.$$

Struktur model:

$$P(y = j) = \frac{e^{V_j}}{e^{V_A} + e^{V_B} + e^{V_C}}, \quad V_j = \beta_{j0} + \beta_{j1}x_1 + \beta_{j2}x_2 + \beta_{j3}x_3.$$

Ambil *C* sebagai base category $\Rightarrow V_C = 0$.

Koefisien estimasi:

Kategori	β_0	β_1	β_2	β_3
<i>A</i>	0.5	0.3	0.2	0.1
<i>B</i>	-0.2	0.1	0.4	0.3
<i>C</i> (base)	0	0	0	0

Contoh Pengerjaan Multinomial Logit (2/3)

Langkah 3 – Hitung nilai-nilai linear V_j :

$$V_A = 0.5 + 0.3(2) + 0.2(1) + 0.1(3) = 0.5 + 0.6 + 0.2 + 0.3 = 1.6,$$

$$V_B = -0.2 + 0.1(2) + 0.4(1) + 0.3(3) = -0.2 + 0.2 + 0.4 + 0.9 = 1.3,$$

$$V_C = 0.$$

Interpretasi:

- V_A, V_B, V_C merepresentasikan “utility scores” relatif.
- Semakin besar V_j , semakin kuat kecenderungan untuk memilih kelas j .

$$(V_A, V_B, V_C) = (1.6, 1.3, 0)$$

Selanjutnya: ubah skor-skor ini menjadi probabilitas.

Contoh Pengerjaan Multinomial Logit (3/3)

Langkah 4 – Lakukan eksponensiasi dan normalisasi:

$$e^{V_A} = e^{1.6} = 4.95, \quad e^{V_B} = e^{1.3} = 3.67, \quad e^{V_C} = e^0 = 1.00.$$

$$D = 4.95 + 3.67 + 1 = 9.62.$$

Langkah 5 – Hitung probabilitasnya:

$$P(A) = \frac{4.95}{9.62} = 0.514, \quad P(B) = \frac{3.67}{9.62} = 0.381, \quad P(C) = \frac{1}{9.62} = 0.104.$$

Aturan keputusan (argmax):

$$\hat{y} = \arg \max_j P(y = j) \Rightarrow \hat{y} = A.$$

Odds ratios relatif terhadap C:

$$\frac{P(A)}{P(C)} = e^{V_A - V_C} = e^{1.6} = 4.95, \quad \frac{P(B)}{P(C)} = e^{1.3} = 3.67.$$

Huruf A memiliki probabilitas tertinggi (51%), sehingga prediksinya adalah A.

Mengestimasi Model di Stata

Langkah 1. Impor data

Dataset tersebut memuat 1000 observasi dan 10 variabel ($x_1 - x_9, y$).

Langkah 2. Ubah huruf menjadi angka.

Mengonversi label huruf (A, B, C) menjadi kode 1, 2, 3.

Langkah 3. Estimasi model mlogit

$$P(y = j) = \frac{e^{x\beta_j}}{\sum_k e^{x\beta_k}}$$

Langkah 4. Memprediksi probabilitas

Menghasilkan variabel probabilitas: pA, pB, pC.

Langkah 5. Klasifikasi

Gunakan aturan *argmax* untuk memilih huruf dengan probabilitas tertinggi.

Langkah 6. Evaluasi

Tampilkan *confusion matrix* dan hitung akurasi model.

Kode Stata

```
import delimited "handwriting_ABC.csv", clear
encode letter, gen(y)
mlogit y x1-x9
predict pA pB pC, pr
egen pmax = rowmax(pA pB pC)
gen pred = .
replace pred = 1 if pA >= pB & pA >= pC
replace pred = 2 if pB > pA & pB >= pC
replace pred = 3 if pC > pA & pC > pB
label values pred y
tab y pred, row col
gen correct = (y == pred)
summ correct
di "Accuracy = " %6.2f r(mean)*100 "% correct"
```

Motivasi (1/2): Pilihan Kategoris Tanpa Urutan Alami

Banyak keputusan di dunia nyata berbentuk kategori *tanpa urutan alami*.

- **Jenis asuransi:** *indemnity*, *prabayar*, atau *tanpa asuransi*. Tidak ada urutan “lebih baik” atau “lebih tinggi” di antara ketiganya—semuanya hanyalah *label*.
- **Moda transportasi:** *mobil*, *bus*, *kereta api*, *sepeda motor*. Pilihan-pilihan ini tidak dapat diperingkat secara logis; perbedaannya terletak pada jenisnya, bukan pada tingkatannya.
- **Merek produk:** *Merek A*, *Merek B*, *Merek C*. Kode angka (1, 2, 3) hanyalah simbol, bukan ukuran.

Apa yang ingin kita pelajari?

- Bagaimana karakteristik individu (X : pendapatan, usia, jenis kelamin, lokasi) memengaruhi *probabilitas* pemilihan setiap kategori.
- Contoh: “Apakah responden non-kulit putih lebih cenderung memilih asuransi *prabayar* dibandingkan *asuransi ganti rugi (indemnity)*, setelah mengendalikan faktor-faktor lain?”

Intinya: Data semacam ini tidak memiliki hubungan “lebih besar dari” antar-kategori; kita memerlukan model yang dapat menangani pilihan nominal ($J \geq 3$).

Motivasi (2/2): Mengapa Kita Membutuhkan Model Baru?

Mengapa regresi biasa tidak cukup?

- **logit biner** (logit / logistic) hanya menangani dua kategori (ya/tidak). Jika kita memaksakan tiga kategori menjadi dua, informasi penting akan hilang.
- **Ordered logit** (ologit) mengasumsikan adanya *urutan alami* (rendah–sedang–tinggi) yang tidak sesuai untuk data nominal, seperti jenis asuransi atau merek.

Yang kita butuhkan: sebuah model untuk variabel *nominal* dengan lebih dari dua kategori.

- Memperlakukan kategori sebagai *label*, bukan sebagai angka yang dapat diurutkan.
- Menghasilkan probabilitas untuk setiap kategori berdasarkan faktor-faktor penjelas (X).

Solusinya → Multinomial Logistic Regression

- Disebut juga **polytomous logit model** atau **MNL**.
- Menghubungkan probabilitas setiap kategori dengan karakteristik individu.
- Di Stata, hal tersebut dijalankan dengan perintah `mlogit`.

Kapan Menggunakan Model Multinomial Logit (mlogit)?

Setiap jenis variabel dependen kategorikal memerlukan model yang berbeda.

Situasi	Model yang Tepat
Dua kategori (ya/tidak)	logit / logistic
Kategori berurutan (rendah–sedang–tinggi)	ologit (ordered logit)
Kategori tak berurutan, kategori ≥ 3	mlogit (multinomial logit)

Penjelasan singkat:

- Hanya dua pilihan $\rightarrow$ gunakan logit.
- Pilihan dengan urutan alami (pendidikan, kepuasan) $\rightarrow$ ologit.
- Pilihan tak berurutan (moda transportasi, jenis asuransi, merek) $\rightarrow$ mlogit.

Intinya:

- mlogit digunakan untuk variabel nominal dengan kategori ≥ 3 .
- Model tersebut menghitung probabilitas relatif setiap kategori terhadap *base outcome*.

Contoh: Variabel *insure* memiliki tiga kategori — *Indemnity*, *Prepaid*, dan *Uninsured*.

Kode Stata

```
use https://www.stata-press.com/data/r19/sysdsn1
tabulate insure nonwhite, chi2 col
```

Gunakan perintah: `mlogit insure age male nonwhite.`

Contoh Konseptual: Pilihan Jenis Mobil (Multinomial Logit)

Variabel dependen (y)

- 1 = Amerika
- 2 = Jepang
- 3 = Eropa

Sifat data:

- Tidak ada tatanan alami.
- Angka 1–3 hanyalah label, bukan nilai.
- Karena bersifat nominal dengan kategori $> 2 \rightarrow$ gunakan `mlogit`.

Bukan model lain:

- `logit`: hanya dua kategori.
- `ologit`: memerlukan urutan alami.

Tujuan:

- Nilailah pengaruh X (pendapatan, usia, jenis kelamin) terhadap probabilitas pemilihan setiap mobil.
- Contoh: pendapatan lebih tinggi $\rightarrow$ lebih cenderung memilih mobil Eropa?

Inti dari model tersebut:

- `mlogit` menghitung probabilitas relatif setiap kategori terhadap *base outcome*.
- Hasil: probabilitas setiap pilihan bagi setiap individu.

Sintaks Stata:

Kode Stata

```
mlogit cartype income age gender
```

Formulasi Model: Multinomial Logit (MNL)

Probabilitas kategori i (dengan kovariat X):

$$\Pr(y = i \mid X) = \frac{\exp(X\beta_i)}{\sum_{m=1}^M \exp(X\beta_m)}, \quad i = 1, \dots, M$$

Catatan mengenai model tersebut:

- Setiap kategori i memiliki *vektor koefisiennya* sendiri, β_i .
- Untuk tujuan identifikasi, pilih satu *base category* dan tetapkan $\beta_{\text{base}} = 0$.
- **Interpretasi koefisien** selalu *bersifat relatif terhadap basis*: untuk variabel x_k , $e^{\beta_{ik}}$ merupakan *relative risk ratio* (kategori i dibandingkan dengan basis) ketika x_k meningkat sebesar satu unit.

$(\sum_{i=1}^M \Pr(y = i \mid X) = 1$. Pemilihan basis mengubah parametrisasi, *bukan* predicted probabilities.)

Base Outcome dan Identifikasi Model

Masalah identifikasi:

- Model `mlogit` tidak teridentifikasi jika semua kategori memiliki koefisien bebas.
- Satu kategori harus berfungsi sebagai *acuan* (base outcome).

Menetapkan base outcome:

- Sebagai contoh, jika base category = 1, maka tetapkan $\beta_1 = 0$.
- Kategori-kategori lainnya ($\beta_2, \beta_3, \dots$) diestimasi relatif terhadap base category.

Interpretasi:

- Sebuah koefisien menunjukkan perubahan dalam probabilitas relatif (log-relative risk) antara kategori i dan base category ketika X berubah sebesar satu unit.
- Predicted probabilities *tidak berubah* meskipun basis yang berbeda dipilih.

Catatan: Pemilihan basis hanya memengaruhi skala koefisien, bukan probabilitas yang dihasilkan ataupun kesimpulan ekonomi.

Relative-Risk Ratio (RRR) dalam Model Multinomial Logit

Konsep dasar:

- Koefisien dari `mlogit` (β) merupakan *log-relative risks*.
- Untuk interpretasi yang lebih intuitif, gunakan bentuk eksponensial:

$$RRR = e^{\beta}$$

Arti nilai RRR:

- $RRR > 1$: peningkatan X menaikkan probabilitas relatif kategori i terhadap kategori dasar. $RRR < 1$ menunjukkan hal sebaliknya.
- $RRR = 1$: X tidak memiliki efek.

Catatan penting:

- RRR berbeda dari *odds ratio* yang digunakan dalam logit biner.
- RRR mengukur perubahan relative risk antar-kategori, bukan odds menang/kalah.
- Gunakan RRR untuk menginterpretasikan pengaruh variabel-variabel dalam `mlogit`.

Kode Stata

```
mlogit insure nonwhite, rrr
```

Interpretasi: $RRR < 1$ berarti variabel tersebut menurunkan probabilitas relatif kategori tersebut dibandingkan dengan base category.

Dasar-dasar Perintah `mlogit` di Stata

Tujuan:

- Jalankan regresi multinomial logit untuk variabel dependen kategorikal.
- Mengukur pengaruh variabel penjelas (X) terhadap probabilitas pemilihan setiap kategori.

Sintaks dasar:

```
mlogit depvar indepvars
```

Opsi penting:

- `baseoutcome(#)` – memilih base category.
- `rrr` – menampilkan *Relative-Risk Ratio* (e^{β}).
- `vce(robust)` – menghasilkan *standard errors yang robust*.

Contoh:

Kode Stata

```
mlogit insure nonwhite age income,  
      baseoutcome(2) rrr vce(robust)
```

Catatan: kategori 2 digunakan sebagai *acuan*, hasil ditampilkan sebagai RRRs, dan standard errors dihitung secara robust.

Demo 1: Memuat Data & Meninjau Tabulasi

Langkah: muat data contoh dan lihat tabulasi awal.

Kode Stata

```
use https://www.stata-press.com/data/r19/sysdsn1  
tabulate insure nonwhite, chi2 col
```

Deskripsi variabel:

- insure (jenis asuransi): 1 = Indemnity, 2 = Prepaid, 3 = Uninsured.
- nonwhite (ras): 0 = Kulit putih, 1 = Bukan kulit putih.

Catatan mengenai keluaran tabulate dengan chi2 col:

- chi2: Uji asosiasi chi-square antara insure dan nonwhite.
- col: persentase kolom (komposisi insure dalam setiap nilai nonwhite).

Demo 2: Menjalankan Model Dasar

Langkah: Jalankan model multinomial logit paling sederhana, dengan satu variabel penjelas.

Kode Stata

```
mlogit insure nonwhite
```

Penjelasan:

- Stata secara otomatis memilih kategori yang paling sering muncul sebagai *base outcome*.
- Hasil keluaran tersebut menampilkan dua set koefisien: untuk kategori *Prepaid* dan *Uninsured*.
- Setiap koefisien diinterpretasikan *relatif terhadap base category* (dalam hal ini = *Indemnity*).

Catatan mengenai penafsiran:

- Sebuah koefisien menunjukkan perubahan dalam *log-relative risk* terhadap base category akibat perubahan pada *nonwhite*.
- Nilai positif $\rightarrow$ probabilitas relatif meningkat; nilai negatif $\rightarrow$ probabilitas relatif menurun.

Demo 3: Mengubah Base Category (Base Outcome)

Langkah: Ubah base category sehingga interpretasinya berbeda, sementara probabilitasnya tetap sama.

Kode Stata

```
mlogit insure nonwhite, baseoutcome(2)
```

Penjelasan:

- Opsi `baseoutcome(2)` menetapkan kategori 2 (*Prepaid*) sebagai *base outcome*.
- Perubahan ini tidak mengubah predicted probabilities, melainkan hanya perspektif interpretasinya.
- Koefisien-koefisien tersebut kini menunjukkan perubahan probabilitas relatif terhadap *Prepaid*, bukan *Indemnity*.

Catatan:

- Pemilihan basis tidak memengaruhi kesimpulan ekonomi ataupun hasil model.
- Gunakan dasar yang paling relevan dengan konteks penelitian agar interpretasinya lebih bermakna.

Demo 4: Menampilkan Relative-Risk Ratio (RRR)

Langkah: Tampilkan hasil model sebagai *Relative-Risk Ratios (RRR)* untuk mempermudah interpretasi.

Kode Stata

```
mlogit insure nonwhite, rrr
```

Menjelaskan hasil-hasilnya:

- RRR untuk nonwhite (Indemnity vs. Prepaid) = 0.52.
- Hal ini berarti individu nonkulit putih memiliki probabilitas relatif yang lebih rendah untuk memilih *Indemnity* 48% dibandingkan *Prepaid*.
- Nilai `_cons` menunjukkan *relative risk dasar* untuk setiap kategori ketika semua variabel $X = 0$.

Interpretasi praktis:

- $RRR < 1 \rightarrow$ variabel tersebut menurunkan probabilitas relatif terhadap base category.
- $RRR > 1 \rightarrow$ variabel tersebut meningkatkan probabilitas relatif terhadap base category.
- `rrr` merupakan cara yang paling umum untuk melaporkan hasil `mlogit` dalam penelitian terapan.

Demo 5: Mengilustrasikan Perhitungan Probabilitas

Tujuan: Menunjukkan bagaimana koefisien `mlogit` digunakan untuk menghitung probabilitas aktual setiap kategori.

Untuk kelompok Putih:

$$Pr(\text{Prepaid}) = \frac{e^{-0.188}}{1 + e^{-0.188} + e^{-1.942}} = 0.42$$

Untuk kelompok non-kulit putih:

$$Pr(\text{Prepaid}) = \frac{e^{-0.188+0.661}}{1 + e^{-0.188+0.661} + e^{-1.942+0.378}} = 0.57$$

Interpretasi:

- Probabilitas memilih *Prepaid* meningkat dari 42% ke 57% bagi individu nonkulit putih.
- Perbedaan ini mencerminkan pengaruh koefisien `nonwhite` terhadap probabilitas aktual.
- Probabilitas-probabilitas ini persis sama dengan hasil tabulasi kolom (`tabulate insure nonwhite, col`).

Kesimpulan: Model `mlogit` tidak hanya menghasilkan koefisien, tetapi juga memungkinkan kita untuk menghitung predicted probabilities bagi setiap kategori.

Demo 5: Menambahkan Lebih Banyak Prediktor

Langkah: Tambahkan variabel penjelas kontinu dan kategorikal ke dalam model.

Kode Stata

```
mlogit insure age male nonwhite i.site
```

Penjelasan:

- Variabel `age` bersifat kontinu; `male` dan `nonwhite` merupakan dummies (0/1).
- `i.site` menunjukkan variabel kategorikal (faktor); Stata secara otomatis membuat *variabel dummy* untuk setiap kategori.
- Model ini mengestimasi bagaimana setiap faktor (usia, jenis kelamin, ras, dan lokasi) memengaruhi probabilitas pemilihan jenis asuransi tertentu.

Interpretasi:

- Perhatikan koefisien atau RRRs untuk setiap kategori `site` guna melihat bagaimana lokasi memengaruhi pilihan asuransi.
- Jika $RRR > 1$ untuk *Uninsured*, individu di lokasi tersebut lebih mungkin tidak memiliki asuransi dibandingkan dengan mereka yang berada dalam base category.

Demo 6: Menafsirkan Hasil

Hasil utama dari model tersebut:

- male: $RRR > 1 \rightarrow$ laki-laki lebih cenderung memilih *Prepaid* dibandingkan base category (*Indemnity*).
- age: koefisien negatif $\rightarrow$ usia lebih tua $\rightarrow$ probabilitas lebih rendah untuk memilih *Prepaid*.
- site 2: signifikan $\rightarrow$ individu di lokasi 2 memiliki probabilitas lebih rendah untuk *tidak Uninsured*.

Makna ekonomi:

- $RRR > 1$ menunjukkan peningkatan probabilitas relatif terhadap base category.
- $RRR < 1$ menunjukkan penurunan probabilitas relatif terhadap base category.

Uji signifikansi:

- Gunakan statistik z , nilai- p , dan selang kepercayaan (CI) untuk menilai apakah suatu efek signifikan secara statistik.
- Pengaruh signifikan $\rightarrow$ variabel tersebut memiliki pengaruh nyata terhadap probabilitas pemilihan kategori tertentu.
- Efek tidak signifikan $\rightarrow$ pengaruh variabel tersebut tidak cukup kuat untuk dibedakan dari nol.

Catatan: Saat melaporkan hasil, fokuslah pada arah, besaran, dan signifikansi efek, bukan hanya tanda koefisiennya.

Demo 7: Pengujian Hipotesis

Tujuan: Menguji apakah suatu variabel, atau seluruh koefisien untuk suatu kategori, berbeda dari nol.

Wald test (uji langsung terhadap hasil estimasi):

Kode Stata

```
test [Uninsure]
```

Arti:

- Menguji apakah semua koefisien untuk kategori *Uninsured* sama dengan 0.
- Jika ditolak ($p < 0.05$) → kategori *Uninsured*) dipengaruhi secara signifikan oleh variabel-variabel penjelas.

Likelihood-Ratio test (LR test):

Kode Stata

```
estimates store unconstrained  
constraint 1 [Uninsure]  
mlogit insure age male nonwhite, constraints(1)  
lrtest unconstrained .
```

Arti:

- Membandingkan model lengkap (*tanpa batasan*) dengan model terbatas (*dengan batasan*).
- Jika LR test signifikan → model dengan batasan memiliki kecocokan yang lebih buruk → koefisien tidak sama dengan nol.

Demo 8: Predicted Probabilities (*Post-Estimation*)

Tujuan: Menghitung dan memvisualisasikan predicted probabilities untuk setiap kategori berdasarkan karakteristik tertentu.

Langkah:

Kode Stata

```
margins, at(nonwhite=(0 1)) predict(outcome(2))
marginsplot
```

Penjelasan:

- Perintah `margins` menghitung predicted probability untuk memilih *Prepaid* (`outcome(2)`).
- `at(nonwhite=(0 1))` membandingkan dua kelompok: kulit putih dan bukan kulit putih.
- `marginsplot` menampilkan hasil dalam bentuk diagram batang atau titik beserta interval kepercayaan.

Interpretasi:

- Grafik tersebut menunjukkan perbedaan probabilitas pemilihan asuransi *Prepaid* antar-kelompok ras.
- Sangat berguna untuk menyampaikan hasil dengan cara *yang relevan bagi kebijakan*.
- Perbedaan visual tersebut membantu menjelaskan pengaruh `nonwhite` terhadap pilihan asuransi secara intuitif.

Demo 9: Marginal Effects (*Post-Estimation*)

Tujuan: Mengukur seberapa besar perubahan probabilitas suatu kategori ketika variabel penjelas berubah sebesar satu unit.

Langkah:

Kode Stata

```
margins, dydx(*) predict(outcome(2))
```

Arti:

- Menghitung marginal effect parsial:

$$\frac{\partial Pr(y = 2)}{\partial X}$$

yaitu, perubahan probabilitas memilih *Prepaid* akibat perubahan satu unit pada X .

- Marginal effects dapat diinterpretasikan secara langsung sebagai perubahan probabilitas, bukan sebagai log-odds atau RRRs.
- Sangat cocok untuk menjelaskan dampak ekonomi secara intuitif—misalnya, “bukan berkulit putih meningkatkan probabilitas memilih *Prepaid* sebesar 0.15.”

Catatan:

- Dapat digunakan untuk setiap kategori (`predict(outcome(#))`) atau untuk model secara keseluruhan.
- Gunakan bersama dengan `marginsplot` untuk memvisualisasikan perubahan probabilitas.

Conditional Logit: Ketika Pilihan Itu Sendiri Memiliki Atribut

Sejauh ini, pada `mlogit`: variabel penjelas menggambarkan *pihak pemilih* (usia, pendapatan, ras). Paket asuransi tidak memiliki variabelnya sendiri.

Namun, sering kali pilihan-pilihan tersebut memiliki atribut: tarif dan waktu tempuh setiap moda, harga setiap ponsel, bentuk setiap kuda, serta jumlah dealer untuk setiap merek mobil di kota Anda.

Conditional logit (McFadden, 1974)

Pemilihan di antara alternatif-alternatif J di mana probabilitas masing-masing alternatif bergantung pada **atribut-atribut alternatif tersebut**, dengan **satu** koefisien untuk setiap atribut yang berlaku sama bagi semua alternatif.

Contoh yang digunakan (dataset Stata `choice`). Sebanyak 295 pembeli mobil masing-masing memilih mobil buatan **Amerika**, **Jepang**, atau **Eropa**. Untuk setiap pembeli, tersedia informasi mengenai **jumlah dealer** dari setiap merek di kota tempat tinggal mereka, serta jenis kelamin dan pendapatan mereka.

Tujuan pembelajaran

- Tuliskan modelnya dan lihat mengapa hanya *perbedaan* pada atribut yang penting.
- Susun data dalam bentuk *panjang* dan lakukan estimasi menggunakan `clogit`.
- Bandingkan dengan `mlogit` dan lihatlah bahwa keduanya merupakan satu model.

Model

Individu i dihadapkan pada alternatif-alternatif $j = 1, \dots, J$. Alternatif j memiliki atribut z_{ij} (jumlah dealer merek j di kota i). Maka

$$V_{ij} = \gamma' z_{ij}, \quad P(i \text{ memilih } j) = \frac{e^{V_{ij}}}{\sum_{k=1}^J e^{V_{ik}}}, \quad \frac{P(i \text{ memilih } j)}{P(i \text{ memilih } k)} = e^{\gamma'(z_{ij} - z_{ik})}.$$

- Rumus probabilitasnya **sama dengan yang ada pada mlogit**. Perbedaannya terletak pada apa yang terdapat di dalam V_{ij} : indeks alternatif j berada pada *variabel* z_{ij} , dan γ merupakan **satu vektor untuk semua alternatif**.
- γ_k adalah **marginal utility** dari atribut k , terlepas dari alternatif mana yang menyediakannya.
- Dalam perhitungan odds dua alternatif, penyebutnya saling meniadakan: hanya **perbedaan** atributlah yang berpengaruh. Segala sesuatu yang sama di antara kedua alternatif tersebut akan tereliminasi.
- Jadi, γ **tidak memerlukan base category**; metode ini diidentifikasi secara langsung dari perbedaan-perbedaannya.
- Konstanta spesifik α_j dapat ditambahkan, namun salah j harus ditetapkan bernilai nol, sebagaimana halnya mlogit z

Data: Satu Baris per Orang $\times$ Alternatif

Susunan yang diminta clogit ([R] clogit, Example 1):

- observasi **dikelompokkan**; variabel kelompoknya di `group()`;
- variabel dependen **0/1**: 1 untuk alternatif yang dipilih, 0 untuk lainnya;
- dalam model pilihan tiap kelompok punya **tepat satu** angka 1.

Bacalah tabel tersebut:

- Tiga baris per pembeli, satu per merek; id adalah grupnya.
- dealer **bervariasi di dalam** pembeli: atribut alternatif.
- sex dan income **berulang di dalam** pembeli: chooser characteristics.
- Pembeli 1 memilih Eropa; pembeli 2 Amerika.

295 pembeli $\times$ 3 merek = 885 baris. Data satu baris per orang? `reshape long` membuat format ini.

Kode Stata

```
use https://www.stata-press.com/data/r19/choice,
clear
list id car choice dealer sex income in 1/6
```

id	car	choice	dealer	sex	income
1	American	0	18	male	46.7
1	Japan	0	8	male	46.7
1	Europe	1	5	male	46.7
2	American	1	17	male	26.1
2	Japan	0	6	male	26.1
2	Europe	0	2	male	26.1

Estimasi di Stata: clogit

Kode Stata

```
clogit choice dealer, group(id)
clogit, or
```

choice	Coef.	Std. err.	z	Odds ratio
dealer	0.0962	0.0091	10.58	1.101

Log likelihood -260.75; 885 baris, 295 kelompok; LR $\chi^2(1) = 126.7$.

Membacanya:

- Satu dealer tambahan menaikkan utility merek itu sebesar 0.096 dan mengalikan **odds-nya terhadap tiap merek lain** dengan $e^{0.096} = 1.10$.
- Tanpa merek dasar, tanpa konstanta: satu baris per atribut.

Mengapa manualnya bicara soal pasangan kasus-kontrol?

- Stata mendokumentasikan clogit sebagai *regresi logistik kondisional (efek tetap)* untuk kasus-kontrol berpasangan: tiap kelompok punya satu “kasus” ($y = 1$) dan “kontrol”-nya ($y = 0$); likelihood dihitung dengan syarat jumlah angka 1 di kelompok.
- Satu situasi pilihan persis seperti itu: alternatif yang dipilih adalah kasusnya, yang ditolak kontrolnya. Likelihood kondisional itu **adalah model pilihan McFadden**, sehingga clogit cocok.
- Variabel yang konstan dalam kelompok gugur; karena itu jenis kelamin dan pendapatan tak bisa masuk apa adanya.

Perintah khusus model pilihan (Stata 16+)

```
cmset id car
cmclogit choice dealer
```

Estimasi sama, plus post-estimation atas alternatif;
asclogit padanan lamanya.

Dari Koefisien ke Probabilitas: Pembeli 1

$\hat{\gamma} = 0.0962$ per dealer. Pembeli 1 melihat 18 dealer Amerika, 8 Jepang, dan 5 dealer Eropa.

make	dealers	V	e^V	P
American	18	1.732	5.65	0.599
Japan	8	0.770	2.16	0.229
Europe	5	0.481	1.62	0.172
sum			9.43	1.000

$V = 0.0962 \times \text{dealers}$. Stata melakukan hal ini untuk setiap baris: `predict p, pc1` menghasilkan 0.599, 0.229, 0.172 untuk pembeli 1.

Pembeli 1 justru membeli mobil Eropa, pilihan yang kemungkinannya paling kecil di antara ketiganya. Model probabilitas memprediksi pangsa, bukan individu.

Bagaimana jika lima dealer Eropa lagi dibuka?

$V_{\text{Europe}} = 0.0962 \times 10 = 0.962$, $e^V = 2.62$, jumlah baru 10.43:

$$P = (0.542, 0.207, \mathbf{0.251})$$

Eropa memperoleh 8 poin. Amerika kehilangan 6 poin dan Jepang kehilangan 2 poin, **secara proporsional terhadap pangsa lama mereka**: Amerika/Jepang sebelumnya berstatus $5.65/2.16 = 2.62$ dan setelahnya menjadi 2.62.

Bagaimana jika setiap merek mendapatkan tiga dealer?

Setiap V meningkat sebesar 0.29; rasio-rasionya tidak berubah; **tidak ada probabilitas yang bergeser**.

Kedua pertanyaan itu tidak dapat diajukan kepada `mlogit`: ia tidak memiliki variabel dealer.

Bandingkan dengan mlogit (1): Dua Jenis Variabel Penjelas

Variabel	Beda antar pembeli?	Beda antar merek?	Jenis
Pendapatan pembeli i	ya	tidak	chooser characteristic x_i
Jenis kelamin pembeli i	ya	tidak	chooser characteristic x_i
Dealer merek j di kota i	ya	ya	Atribut alternatif z_{ij}

Multinomial logit

$$V_{ij} = \alpha_j + \beta_j' x_i$$

x_i : chooser characteristics.

α_j, β_j : satu **set terpisah** untuk setiap merek j .

Salah satu jenisnya adalah basis: $\alpha_{\text{base}} = \beta_{\text{base}} = 0$.

Parameter $(J - 1)(K + 1)$: 3 make, 2 variabel $\Rightarrow 6$.

Conditional logit

$$V_{ij} = \gamma' z_{ij}$$

z_{ij} : atribut-atribut dari j sebagaimana dihadapi oleh pembeli i .

γ : **satu** vektor, sama untuk setiap merek.

Tidak diperlukan dasar untuk γ .

Parameter K : 1 atribut $\Rightarrow 1$, berapa pun jumlah pembuatannya.

Perhatikan indeks bawahnya. Di sebelah kiri, *koefisien* memuat indeks merek j ; sedangkan di sebelah kanan, *variabel* yang memuatnya.

Bandingkan dengan mlogit (2): Mengapa Perbedaan Ini Dipaksakan kepada Kita

odds Jepang melawan Amerika hanya memuat **perbedaan** utilities: $P(\text{Japan})/P(\text{American}) = e^{V_{i,\text{Japan}} - V_{i,\text{American}}}$.

Cobalah pendapatan dengan *satu* koefisien β

$$V_{\text{Japan}} - V_{\text{American}} = \beta \text{inc}_i - \beta \text{inc}_i = 0$$

Bagi setiap pembeli, berapa pun pendapatannya, odds adalah $e^0 = 1$. Pendapatan tidak memberikan pengaruh apa pun: β **tidak teridentifikasi**.

Hal tersebut hanya dapat masuk dengan koefisien yang **berbeda berdasarkan merek**: $(\beta_{\text{Japan}} - \beta_{\text{American}}) \text{inc}_i$.

Cobalah dealer dengan *satu* koefisien γ

$$V_{\text{Japan}} - V_{\text{American}} = \gamma (8 - 18) = -10\gamma$$

Sebuah bilangan riil yang bervariasi antar-pembeli. γ **diidentifikasi**.

Inilah yang dimaksud clogit dengan “dihilangkan karena tidak adanya varians di dalam kelompok”: pendapatan bersifat konstan di dalam kelompok pembeli.

Konsekuensi

chooser characteristic hanya dapat dimasukkan dengan koefisien yang berbeda antar-alternatif (β_j). **Atribut alternatif** dapat dimasukkan dengan satu koefisien (γ). Inilah kedua model tersebut.

Bandingkan dengan mlogit (3): Tata Letak Data dan Perintah

Multinomial logit: format lebar

Satu baris untuk setiap pembeli; hasilnya adalah merek yang dipilih.

id	sex	income	car
1	male	46.7	Europe
2	male	26.1	American
3	male	32.7	American

```
mlogit car sex income, baseoutcome(1)
```

Conditional logit: format panjang

Satu baris untuk setiap $\times$ yang dibuat pembeli, dengan flag choice 0/1.

id	car	dealer	sex	income	choice
1	American	18	male	46.7	0
1	Japan	8	male	46.7	0
1	Europe	5	male	46.7	1

```
clogit choice dealer, group(id)
```

- Dalam tabel panjang, **jenis kelamin dan pendapatan berulang** pada diri seorang pembeli: tanda visual dari chooser characteristic.
- Tata letak memanjang memungkinkan **choice set berbeda** bagi setiap orang: pembeli yang tidak memiliki dealer di Eropa tidak akan memiliki baris untuk Eropa.
- **Membaca koefisien:** mlogit memberikan log-odds *relatif terhadap basis*, yang tandanya tidak harus sama dengan tanda marginal effect. clogit memberikan marginal utility yang sama untuk setiap merek, dan **rasio antar-koefisien merupakan harga**: dalam model pemilihan moda yang melibatkan waktu dan tarif, $\gamma_{\text{time}}/\gamma_{\text{fare}}$ adalah nilai waktu.

Kedua model tersebut adalah model yang sama

Susun multinomial logit dalam format panjang: satu dummy per merek non-dasar, **diinteraksikan** dengan variabel pemilih. Interaksi itu *bervariasi* antar-merek, jadi clogit menerimanya:

Kode Stata

```
gen japan = (car==2)
gen europe = (car==3)
gen japan_sex = japan*sex (demikian pula europe_sex,
japan_inc, europe_inc)
clogit choice japan europe japan_sex europe_sex
      japan_inc europe_inc, group(id)
```

$V_{\text{Amer}} = 0$, $V_{\text{Japan}} = \gamma_1 + \gamma_3 \text{sex}_i + \gamma_5 \text{inc}_i$,
 $V_{\text{Eur}} = \gamma_2 + \gamma_4 \text{sex}_i + \gamma_6 \text{inc}_i$: multinomial logit dengan American sebagai basis.

		mlogit (295 baris)	clogit (885 baris)
Japan	_cons	-1.963	-1.963
	sex	-0.469	-0.469
	income	0.0277	0.0277
Europe	_cons	-3.180	-3.180
	sex	0.539	0.539
	income	0.0274	0.0274
Log likelihood		-252.72	-252.72

Identik, bukan sekadar mendekati. Standard errors pun sama.

Jadi

conditional logit adalah model umum; **multinomial logit** kasus khususnya tanpa atribut asli. **Kedua** jenis variabel sekaligus juga conditional logit, yang tak bisa dipenuhi mlogit: `cmclogit choice dealer, casevars(sex income)` memberi $\hat{\gamma}_{\text{dealer}} = 0.068$ plus koefisien jenis kelamin dan pendapatan per merek.

Apa yang Dapat Dijawab Tiap Model, dan Kelemahan Bersamanya

Multinomial logit

Dapat: menjelaskan bagaimana ciri pemilih berkaitan dengan pilihannya. Siapa yang membeli mobil Jepang?

Tidak dapat: mengatakan apa yang terjadi bila dealer, harga, atau tarif berubah (tidak ada variabelnya); mengatakan apa pun tentang **alternatif baru** (perlu α_j, β_j sendiri, tanpa data untuk mengestimasi).

Conditional logit

Dapat: menjawab pengandaian (what-if) atas atribut. Masukkan **alternatif baru** ke choice set: beri atribut, hitung V -nya, tambahkan ke penyebut.

BART, 1972. Sebelum jalur kereta baru dibuka, conditional logit McFadden, diestimasi pada moda yang ada, meramalkan pangsa 6.3%. Model resmi: 15%. Aktual: 6.2%.

Kesamaan di antara keduanya: independence of irrelevant alternatives (IIA)

Odds dua alternatif mana pun hanya memuat kedua alternatif itu, apa pun yang terjadi pada alternatif ketiga. Ini berlaku sebelum isi V ditentukan, jadi berlaku pada kedua model.

Bus merah, bus biru. Mobil 50%, bus biru 50%. Cat separuh bus jadi merah. Akal sehat: mobil 50, biru 25, merah 25. Logit: mobil 33, biru 33, merah 33. Model tidak tahu bahwa dua bus adalah substitusi dekat dan mobil substitusi jauh. Versi ringannya tampak di slide dealer: dealer Eropa baru mengambil pangsa dari Amerika dan Jepang *secara proporsional*.

Perbaikan: nested logit (nlogit), mixed logit (cmmixlogit), multinomial probit (cmmprobit).

Ringkasan: Satu Halaman untuk Disimpan

	Multinomial logit	Conditional logit
Variabel penjelas	dari sang pemilih , x_i	dari berbagai alternatif tersebut , z_{ij}
Utility	$V_{ij} = \alpha_j + \beta'_j x_i$	$V_{ij} = \gamma' z_{ij}$
Koefisien	satu set per alternatif ; $(J - 1)(K + 1)$	satu set untuk semua alternatif; K
Base category	diperlukan; koefisien yang terkait dengannya	tidak diperlukan untuk γ , hanya untuk konstanta
Tata letak data	lebar: satu baris per orang	panjang: satu baris per orang, alternatif $\times$
Choice set	sama untuk semua orang	mungkin berbeda-beda pada setiap orang
Membaca koefisien	log-odds vs. basis; tanda marginal effect $\neq$	marginal utility; rasio-rasionya adalah harga
Alternatif baru	mustahil	Berikan atribut padanya dan tambahkan
IIA	ya	ya
Stata	mlogit	clogit, cmclogit (asclogit)
Hubungan	kasus khusus	model umum

Versi satu kalimatnya: Apakah indeks alternatif j melekat pada **koefisien** (β_j : multinomial) atau pada **variabel** (z_{ij} : kondisional)? Segala hal lainnya bergantung pada hal tersebut.

Model Ordered Probit: Konsep, Intuisi, dan Implementasi di Stata

Tujuan Pembelajaran

- Memahami logika di balik *model respons terurut*.
- Visualisasikan struktur variabel laten dari model ordered probit (Becker & Kennedy, 1992).
- Pelajari cara mengestimasi dan menginterpretasikan model menggunakan Stata (`oprobit`).
- Terapkan perintah post-estimation (`predict`, `margins`) untuk menginterpretasikan probabilitas.

Kapan Menggunakan Model Ordered Probit

Karakteristik Variabel Dependen:

- Variabel dependen berada pada skala *ordinal* — kategori-kategorinya memiliki urutan, namun jarak di antaranya tidak diketahui secara pasti.

Contoh:

- Tingkat kebahagiaan: 1 = tidak bahagia $\rightarrow$ 4 = sangat bahagia.
- Status kesehatan: buruk $\rightarrow$ cukup $\rightarrow$ baik $\rightarrow$ sangat baik.
- Nilai akhir mata kuliah Ekonometrika Mikro: D $\rightarrow$ C $\rightarrow$ B $\rightarrow$ A.

Mengapa OLS tidak tepat:

- Jarak antar-kategori tidak sama (misalnya, selisih dari C ke B tidak sama dengan dari B ke A).
- Memperlakukan kategori ordinal (1–4) sebagai variabel kontinu memaksakan asumsi linearitas yang keliru.

Kerangka Konseptual (Becker & Kennedy, 1992)

Gagasan Dasar: Latent Variable

- Model *ordered probit* bermula dari asumsi bahwa terdapat latent variable yang tidak teramati:

$$y^* = \alpha + \sum_i \beta_i x_i + \varepsilon$$


di mana $\varepsilon \sim N(0, 1)$.

- latent variable y^* tidak dapat diamati secara langsung; yang kita amati adalah y , yang bersifat diskret dan teratur:

$$y = \begin{cases} 1 & \text{if } y^* \leq \kappa_1, \\ 2 & \text{if } \kappa_1 < y^* \leq \kappa_2, \\ \vdots & \\ J & \text{if } y^* > \kappa_{J-1}. \end{cases}$$

- Parameter κ (cutpoints) merupakan ambang batas yang diestimasi dari data, yang membagi kontinum laten y^* menjadi kategori-kategori hasil yang teramati.

Diagram Becker & Kennedy (Intuisi Tiga Dimensi)



Sumber: Becker & Kennedy (1992) – Penjelasan Grafis mengenai Ordered Probit

Intuisi Visual:

- Sumbu vertikal: kepadatan galat $f(\varepsilon)$ (distribusi normal standar).
- Bidang horizontal:
 - x_k (misalnya: jam belajar, IPK kumulatif, atau tingkat kehadiran),
 - latent index y^* (kemampuan atau kinerja akademik laten).
- Untuk setiap nilai x_k , distribusi normal standar berpusat pada nilai prediksi y^* .
- Ambang batas ($\kappa_1, \kappa_2, \kappa_3, \kappa_4$) membagi area di bawah kurva menjadi probabilitas untuk setiap kategori nilai akhir: **E, D, C, B, A**.
- Peningkatan x_k (misalnya, lebih banyak belajar atau berlatih) menggeser distribusi ke arah kanan, sehingga massa probabilitas berpindah dari nilai rendah (E, D) ke nilai yang lebih tinggi (C, B, A).

Rumus Probabilitas Formal

Formulasi dari Becker & Kennedy (1992) dan Stata:

$$P(y = j \mid x) = \Phi(\kappa_j - x\beta) - \Phi(\kappa_{j-1} - x\beta)$$

$\Phi(\cdot)$ adalah fungsi distribusi kumulatif (CDF) dari distribusi normal standar,

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

Interpretasi:

- Setiap variabel penjelas (*kovariat*) menggeser rata-rata latent index y^* .
- Ambang batas $(\kappa_1, \kappa_2, \dots, \kappa_{J-1})$ bersifat tetap dan sama untuk semua pengamatan.
- Pergeseran $x\beta$ ke arah kanan meningkatkan probabilitas perolehan nilai yang lebih tinggi (misalnya, dari E atau D menjadi C, B, atau A).

Tanda dan Interpretasi Koefisien (β)

Makna Tanda Koefisien:

- $\beta_j > 0$: meningkatkan skor laten y^* , sehingga memperbesar peluang untuk masuk ke kategori nilai yang lebih tinggi (misalnya, dari E atau D menuju C, B, atau A).
- $\beta_j < 0$: menurunkan nilai laten y^* , sehingga probabilitas bergeser ke arah kategori tingkat yang lebih rendah.

Makna Besaran Koefisien:

- Nilai mutlak β tidak dapat ditafsirkan secara langsung dalam satuan probabilitas karena nilainya bergantung pada bentuk distribusi normal baku.
- Untuk interpretasi dalam satuan probabilitas, gunakan **marginal effects** (margins) yang dibahas pada slide-slide berikutnya.

Contoh Implementasi di Stata

Dataset:

- use <https://www.stata-press.com/data/r19/fullauto>
- Variabel dependen: rep77 (catatan perbaikan mobil), pada skala ordinal:
1 = poor, 2 = fair, 3 = good, 4 = very good, 5 = excellent.

Model:

Perintah Stata

```
oprobit rep77 foreign length mpg
```

Hasil Utama yang Ditampilkan:

- Koefisien (β) untuk setiap variabel independen.
- Cutpoints (/cut1 ... /cut4) yang memisahkan kategori hasil.
- Statistik model: log-likelihood, Likelihood Ratio test (χ^2), dan Pseudo- R^2 .

Menginterpretasikan Estimasi Model

Komponen Utama Hasil:

- **Koefisien (β):** Tanda tersebut menunjukkan arah pengaruh terhadap latent variable y^* .
 - $\beta > 0 \Rightarrow$ meningkatkan probabilitas untuk masuk ke dalam kategori yang lebih tinggi.
 - $\beta < 0 \Rightarrow$ menurunkan probabilitas tersebut, beralih ke kategori yang lebih rendah.
- **Cutpoints (/cut1 ... /cut4):** Titik ambang batas yang memisahkan setiap kategori hasil (misalnya, dari nilai 1 ke 2, 2 ke 3, dan seterusnya).

Contoh Interpretasi:

- Mobil buatan luar $\Rightarrow$ foreign = 1.70 cenderung mendapatkan peringkat perbaikan yang lebih tinggi rep77
- Mobil $\Rightarrow$ length = 0.047 panjang cenderung memiliki catatan perbaikan yang lebih baik.

Post-Estimation: Predicted Probabilities

Sintaks Dasar dalam Stata:

Predicted probabilities untuk setiap kategori

```
predict p1 p2 p3 p4 p5
```

- Menghasilkan probabilitas $Pr(y = 1), Pr(y = 2), \dots, Pr(y = 5)$ untuk setiap observasi.

Prediksi untuk kategori tertentu (misalnya $y = 5$)

```
predict p5, outcome(5)
```

- Menghasilkan probabilitas untuk kategori tertinggi saja (misalnya, nilai 5 atau excellent).

Memvisualisasikan Hasil:

Contoh: pengaruh panjang mobil terhadap probabilitas peringkat tertinggi

```
margins, at(length=(140 180 220)) predict(outcome(5))  
marginsplot
```

- Menunjukkan bagaimana perubahan panjang mobil (length) memengaruhi probabilitas memperoleh peringkat perbaikan tertinggi.

Perhitungan Probabilitas secara Manual (Tautan ke Becker & Kennedy)

Tujuan:

- Tunjukkan kesetaraan antara rumus analitis model Becker & Kennedy dan hasil yang diperoleh dari Stata.
- Bantu siswa memahami hubungan antara ekspresi matematis dan luas di bawah kurva distribusi normal.

Langkah-langkah Perhitungan di Stata:

Perintah Stata

```
predict xbhat, xb  
gen prob4 = normal(_b[/cut4] - xbhat) - normal(_b[/cut3] - xbhat)
```

- Baris pertama menghitung nilai prediksi latent index ($x\beta$).
- Baris kedua menghitung secara manual probabilitas bahwa suatu observasi termasuk dalam kategori 4 ($Pr(y = 4)$).
- Hasilnya identik dengan yang diperoleh dari `predict p4, outcome(4)`.

Marginal Effects dan Interpretasi Probabilitas

Perintah di Stata:

Menghitung marginal effects untuk kategori tertinggi ($y = 5$)

```
margins, dydx(length mpg foreign) predict(outcome(5))
```

Interpretasi:

- Peningkatan satu unit pada `length` menaikkan probabilitas mobil menerima `rep77 = 5` sebesar X persen.
- marginal effect menunjukkan perubahan probabilitas suatu kategori tertentu akibat perubahan kecil pada variabel penjelas, dengan menjaga variabel-variabel lain tetap konstan.

Catatan Penting:

- Marginal effects berbeda untuk setiap kategori hasil ($y = 1, 2, 3, 4, 5$).
- Jika dijumlahkan di seluruh kategori, total marginal effects adalah nol:

$$\sum_{j=1}^J \frac{\partial P(y=j)}{\partial x_k} = 0$$

Visualisasi Proses Laten dalam Model Ordered Probit




Diagram konseptual dari Becker & Kennedy (1992)

Intuisi Visual:

- Gabungkan diagram konseptual Becker & Kennedy dengan hasil prediksi Stata (marginsplot).
- Peningkatan pada variabel penjelas (misalnya length) menggeser distribusi y^* ke arah kanan.
- Pergeseran ini mengubah area di bawah ambang batas ($\kappa_1, \kappa_2, \dots$) — yang berarti adanya perubahan pada probabilitas setiap kategori (E, D, C, B, A).

Pesan Utama:

- Model *Ordered Probit* merupakan jembatan antara proses laten kontinu (y^*) dan hasil teramati yang bersifat ordinal (E hingga A).

Perbandingan dengan Model Alternatif

Model yang Relevan:

- **Ordered Logit:** Memiliki struktur yang sama dengan Ordered Probit, namun menggunakan distribusi logistik alih-alih distribusi normal standar.
 - Hasil dan interpretasi yang serupa.
 - Perbedaan utamanya terletak pada bentuk distribusi galat (logistik vs. normal).
- **Multinomial Logit / Probit:** Digunakan untuk hasil *yang tidak memiliki urutan*.
 - Setiap kategori diperlakukan sebagai entitas yang berdiri sendiri (tidak ada urutan alami).
 - Tidak efisien jika datanya sebenarnya bersifat ordinal.
- **Model Linear (OLS / Linear Probability Model):** Tidak cocok untuk skala ordinal.
 - Mengasumsikan jarak yang sama antar-kategori (keliru).
 - Dapat menghasilkan prediksi di luar rentang $[0,1]$.

Kesimpulan Singkat:

- Model *Ordered Probit* merupakan model yang paling tepat untuk data ordinal yang mencerminkan proses laten kontinu dengan ambang batas yang dapat diestimasi.

Langkah 0–1: Persiapan dan Impor Data

Deskripsi:

- Hapus data lama dan matikan jeda keluaran.
- Muat dataset gabungan (train + test) langsung dari situs web kursus menggunakan `use` (tanpa mengunduh).
- Periksa strukturnya dan pastikan variabel-variabelnya sesuai dengan yang diharapkan.
- Konversikan variabel kategorikal menjadi `factor variables`.

Kode Stata

```
clear all
set more off
use https://anshory1972.github.io/miktrik2026/data/grades.dta, clear
describe
summarize attendance_pct grade_numeric
encode prereq_grade, gen(prereq_g)
encode gender, gen(gender_g)
encode lecturer, gen(lecturer_g)
encode dataset, gen(dataset_g)
```

Langkah 2: Mengestimasi Model pada Training Data

Deskripsi:

- Estimasi model Ordered Probit hanya pada training data.
- Variabel dependen: `grade_numeric`.
- Variabel independen: `attendance_pct`, nilai mata kuliah prasyarat, jenis kelamin, dan dosen.
- Simpan hasil estimasi dan tampilkan cutpoints.

Kode Stata

```
oprobit grade_numeric c.attendance_pct  
      i.prereq_g i.gender_g i.lecturer_g if  
dataset=="train"  
  
estimates store OPROBIT_TRAIN  
  
display "Cutpoints:" _b[/cut1] _b[/cut2]  
_b[/cut3] _b[/cut4]
```

Langkah 3: Analisis Marginal Effects

Deskripsi:

- Hitunglah marginal effects variabel-variabel tersebut terhadap probabilitas memperoleh nilai A.
- Gambarkan hubungan antara kehadiran dan probabilitas mendapatkan nilai A.
- Verifikasi bahwa jumlah marginal effects di seluruh kategori adalah 0.

Kode Stata

```
margins, dydx(c.attendance_pct  
i.prereq_g i.gender_g i.lecturer_g)  
    predict(outcome(5))  
  
quietly margins,  
at(attendance_pct=(80(5)100))  
predict(outcome(5))  
marginsplot, title("Pr(A) vs  
Attendance")  
  
margins, dydx(c.attendance_pct)  
predict(outcome(1 2 3 4 5))
```

Langkah 4a: Memprediksi Probabilitas pada Test Data

Deskripsi:

- Gunakan model yang telah diestimasi untuk memprediksi probabilitas setiap kategori (E–A).
- Dapat diterapkan pada observasi di luar sampel (test set).
- Pastikan jumlah probabilitasnya sama dengan 1.

Kode Stata

```
predict p1, outcome(1)
predict p2, outcome(2)
predict p3, outcome(3)
predict p4, outcome(4)
predict p5, outcome(5)

gen p_sum = p1 + p2 + p3 + p4 + p5
summarize p_sum if dataset=="test"
```

Langkah 4b: Modal Prediction dan Nilai Harapan

Deskripsi:

- Identifikasi kategori dengan probabilitas tertinggi (modal prediction).
- Konversikan ke nilai huruf (E–A) untuk pelaporan.
- Hitunglah skor harapan (rata-rata).
- Tampilkan hasil untuk 20 siswa pertama dalam test set.

Kode Stata

```
egen pmax = rowmax(p1 p2 p3 p4 p5)
gen yhat_modal = .
replace yhat_modal = 1 if p1==pmax
replace yhat_modal = 2 if p2==pmax
replace yhat_modal = 3 if p3==pmax
replace yhat_modal = 4 if p4==pmax
replace yhat_modal = 5 if p5==pmax

label define grlab 1 "E" 2 "D" 3 "C" 4 "B" 5 "A"
label values yhat_modal grlab

gen yhat_expected = 1*p1 + 2*p2 + 3*p3 + 4*p4 + 5*p5

list grade_numeric yhat_modal yhat_expected
if dataset=="test" in 1/20
```

Langkah 5: Mengekspor Prediksi Data Uji

Deskripsi:

- Simpan prediksi untuk siswa uji coba ke dalam file CSV.
- Cantumkan hanya variabel-variabel utama: nilai aktual, probabilitas setiap kategori, modal prediction, dan skor yang diharapkan.

Kode Stata

```
preserve
keep if dataset=="test"
keep grade_numeric grade_letter
attendance_pct prereq_grade gender
lecturer
p1 p2 p3 p4 p5 yhat_modal yhat_expected
export delimited using
"test_predictions_from_oprobit.csv",
replace
restore
```

Referensi dan Bacaan I



Becker, W. E. & Kennedy, P. E. (1992). *A Graphical Exposition of the Ordered Probit*. *Econometric Theory*, 8(1), 127–131.



StataCorp LLC. (2025). *[R] oprobit — Ordered probit regression*. College Station, TX: Stata Press. Available at: <https://www.stata.com/manuals/roprobit.pdf>



StataCorp LLC. (2025). *[R] oprobit postestimation — Postestimation tools for oprobit*. College Station, TX: Stata Press. Available at: <https://www.stata.com/manuals/roprobitpostestimation.pdf>